



TRABAJO FIN DE GRADO

ANÁLISIS, DISEÑO E IMPLEMENTACIÓN DE REDES NEURONALES PARA LA PREDICCIÓN DE TEMPERATURA EN CENTROS DE PROCESADO DE DATOS

LUIS CASTEJÓN LOZANO

TUTOR: JOSÉ MANUEL MOYA FERNÁNDEZ

2021

ÍNDICE

- > **NECESIDAD**
- > **OBJETIVOS**
- > **MARCO TEÓRICO**
- > **ESTADO DEL ARTE**
- > **DESARROLLO**
- > **RESULTADOS**
- > **CONCLUSIONES**

NECESIDAD

NECESIDAD

- Crecimiento masivo del uso de Internet y servicios en la nube



- Alta demanda de centros de procesado de datos

- Alto consumo energético

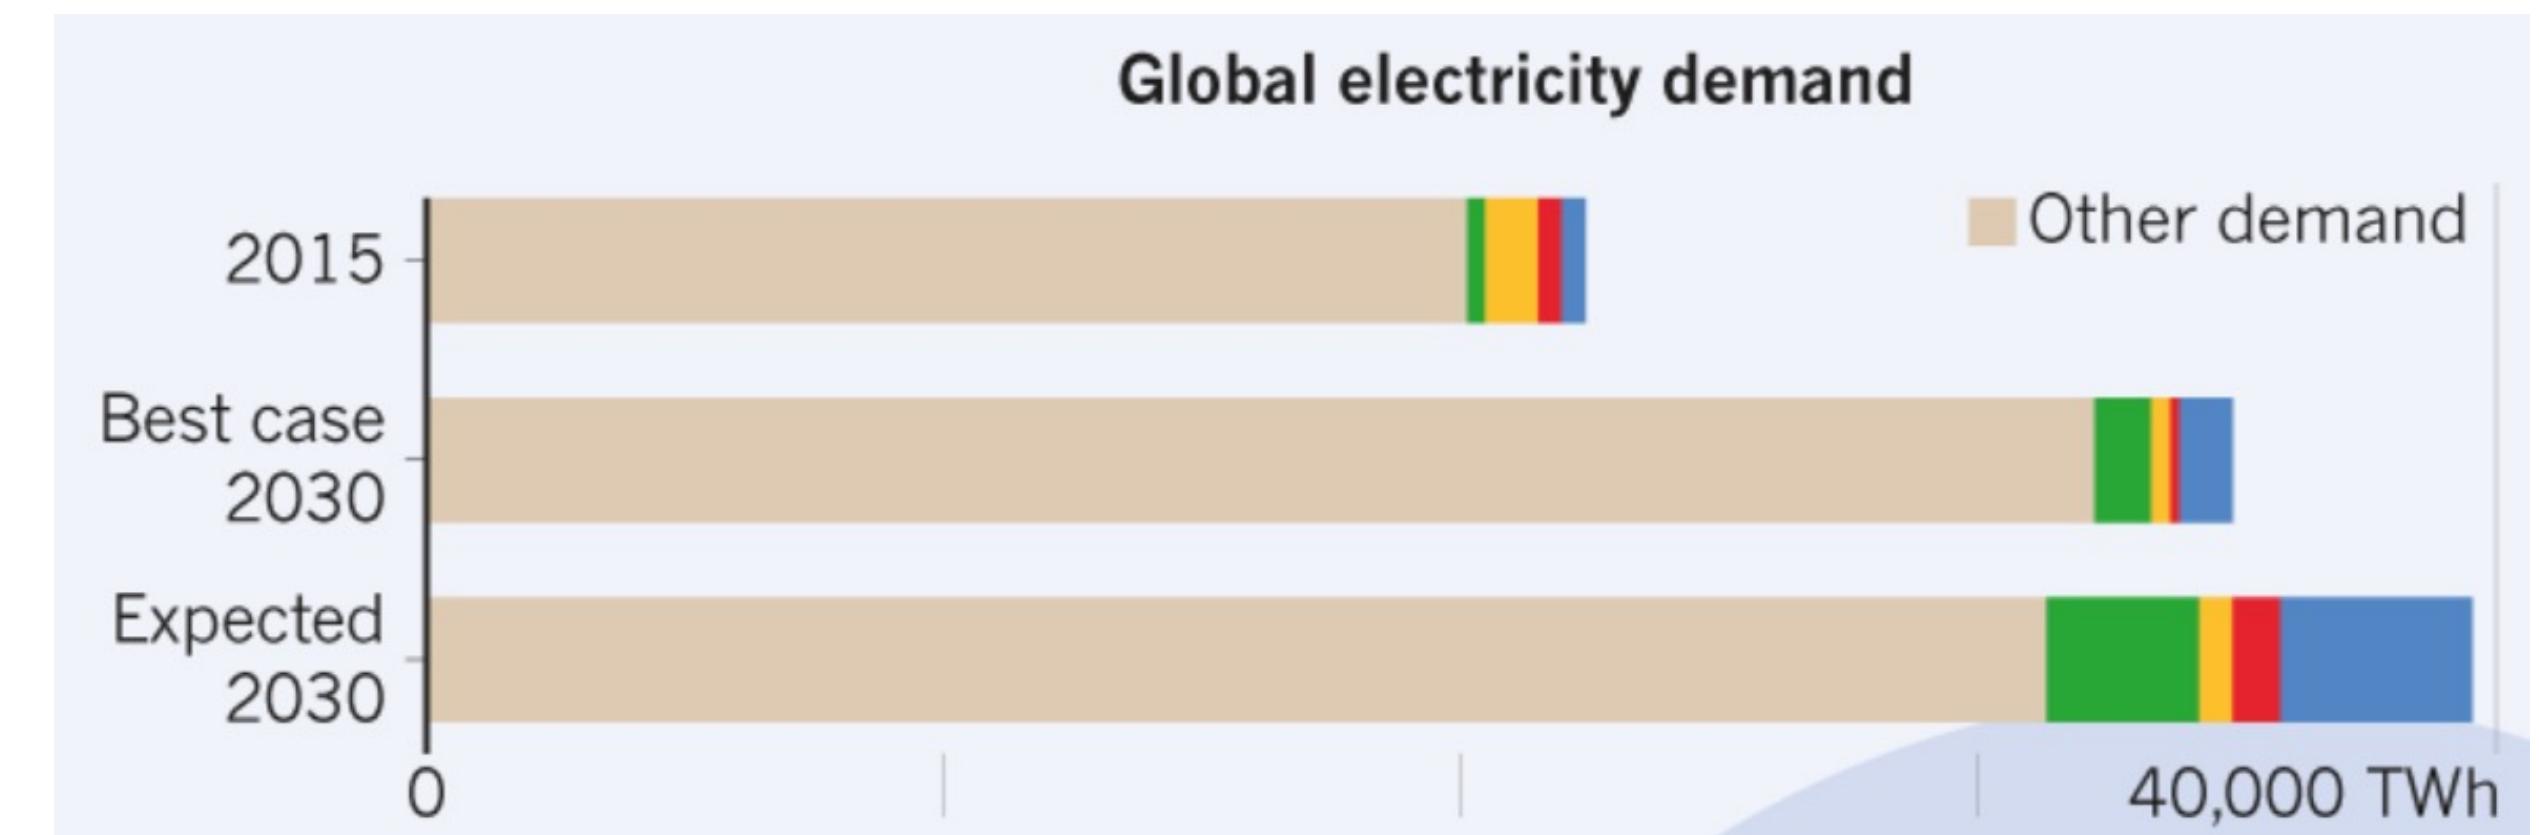
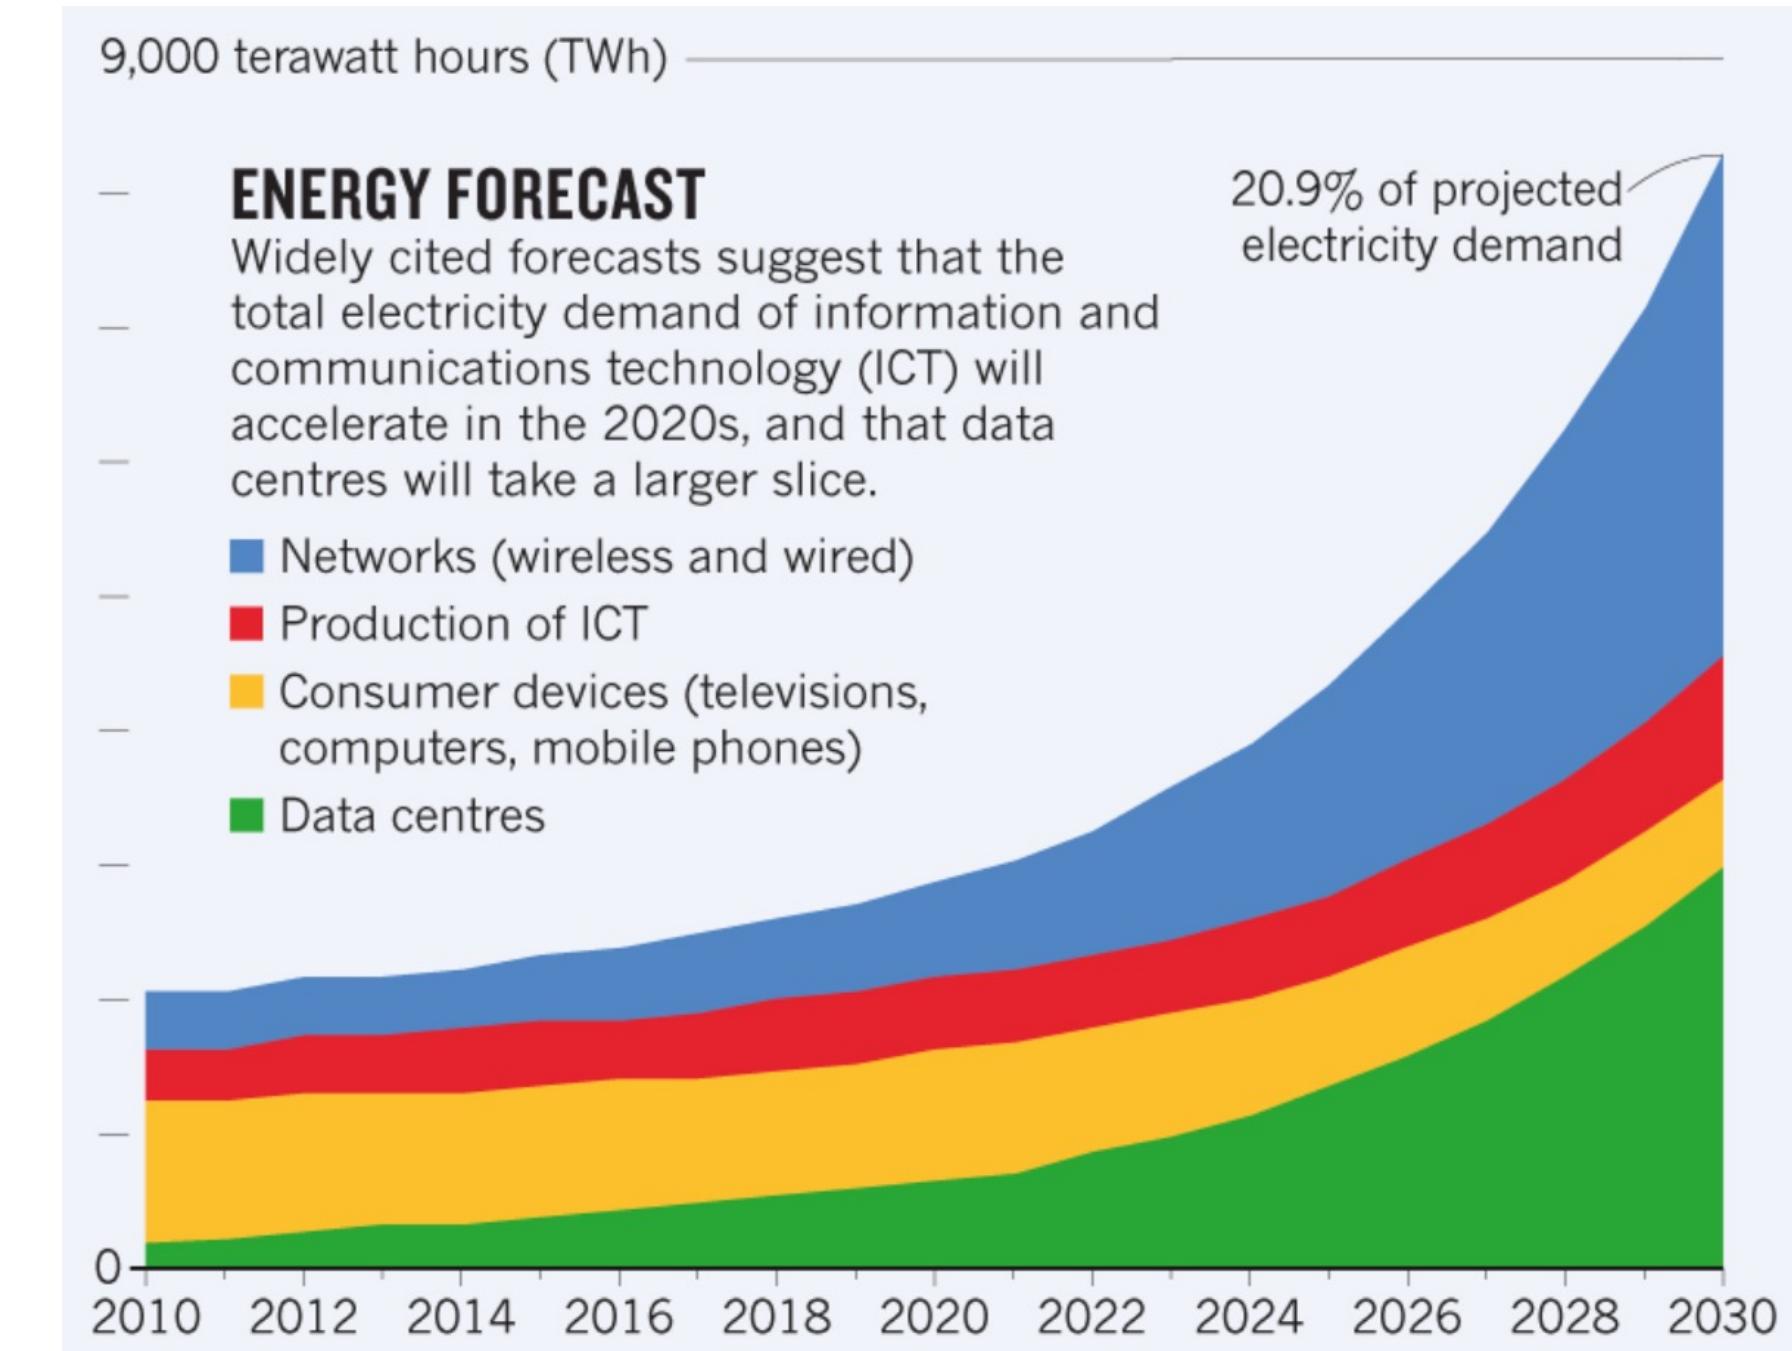
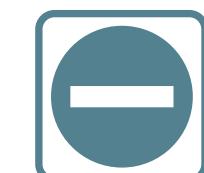


- Huella de carbono



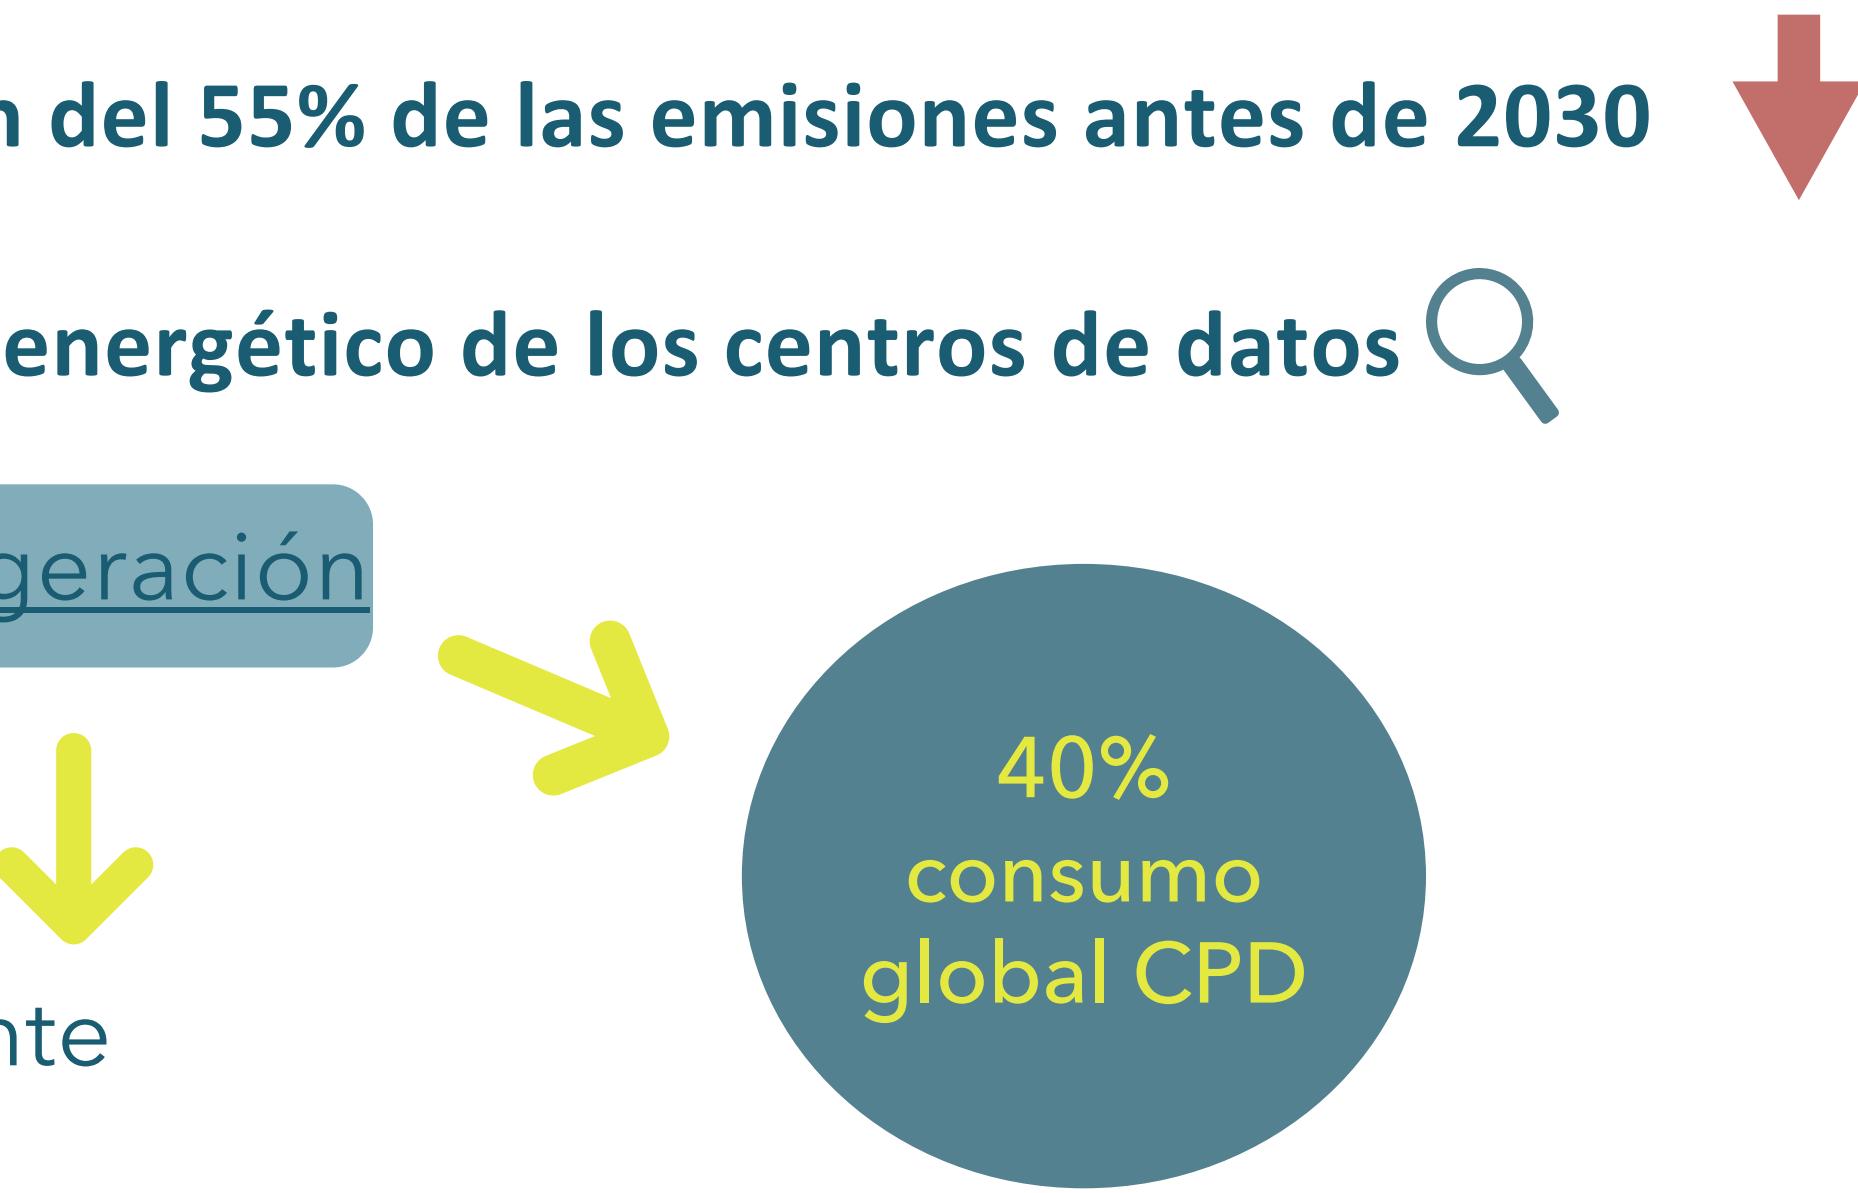
sector TIC 2%

- Incremento preocupante



NECESIDAD

- › **Pacto Verde Europeo** → reducción del 55% de las emisiones antes de 2030
- › Iniciativas para reducir el consumo energético de los centros de datos 
- › Reducción consumo de refrigeración
 - › Ineficiente actualmente
 - › No se adapta a las condiciones de cada momento
 - › Fundamental para un buen rendimiento del centro de datos



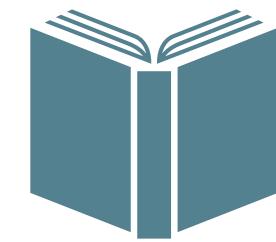
OBJETIVOS

OBJETIVOS (I)

1. Desarrollo de un sistema de predicción fiable de temperatura basado en redes neuronales ✓

1. Controlar el nivel de refrigeración a lo largo del tiempo para reducir el consumo ⚡
2. Aprendizaje con mediciones de temperatura y humedad en sensores

2. Estudio y adquisición previa de nuevos conocimientos



1. Situación sector CPD así como su infraestructura, enfocándose funcionamiento refrigeración
2. Fundamentos aprendizaje automático, redes neuronales (recurrentes y convolucionales)
3. Python, Keras, TensorFlow y librerías (Pandas)

OBJETIVOS (II)

3. Analizar una reducción del número de mediciones sin perder calidad de resultados

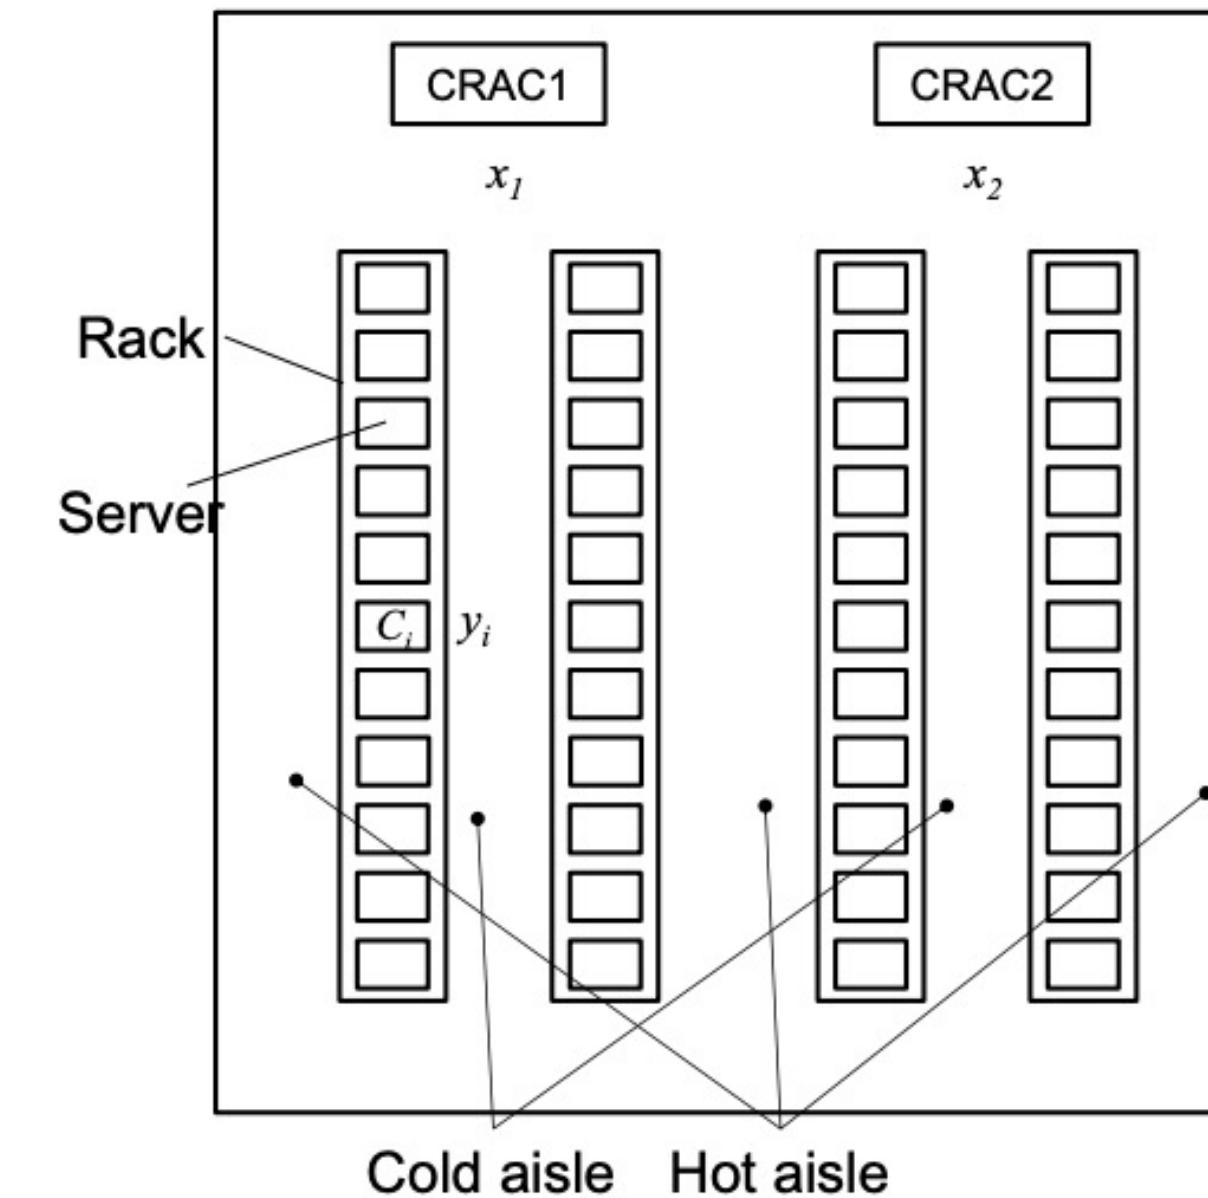
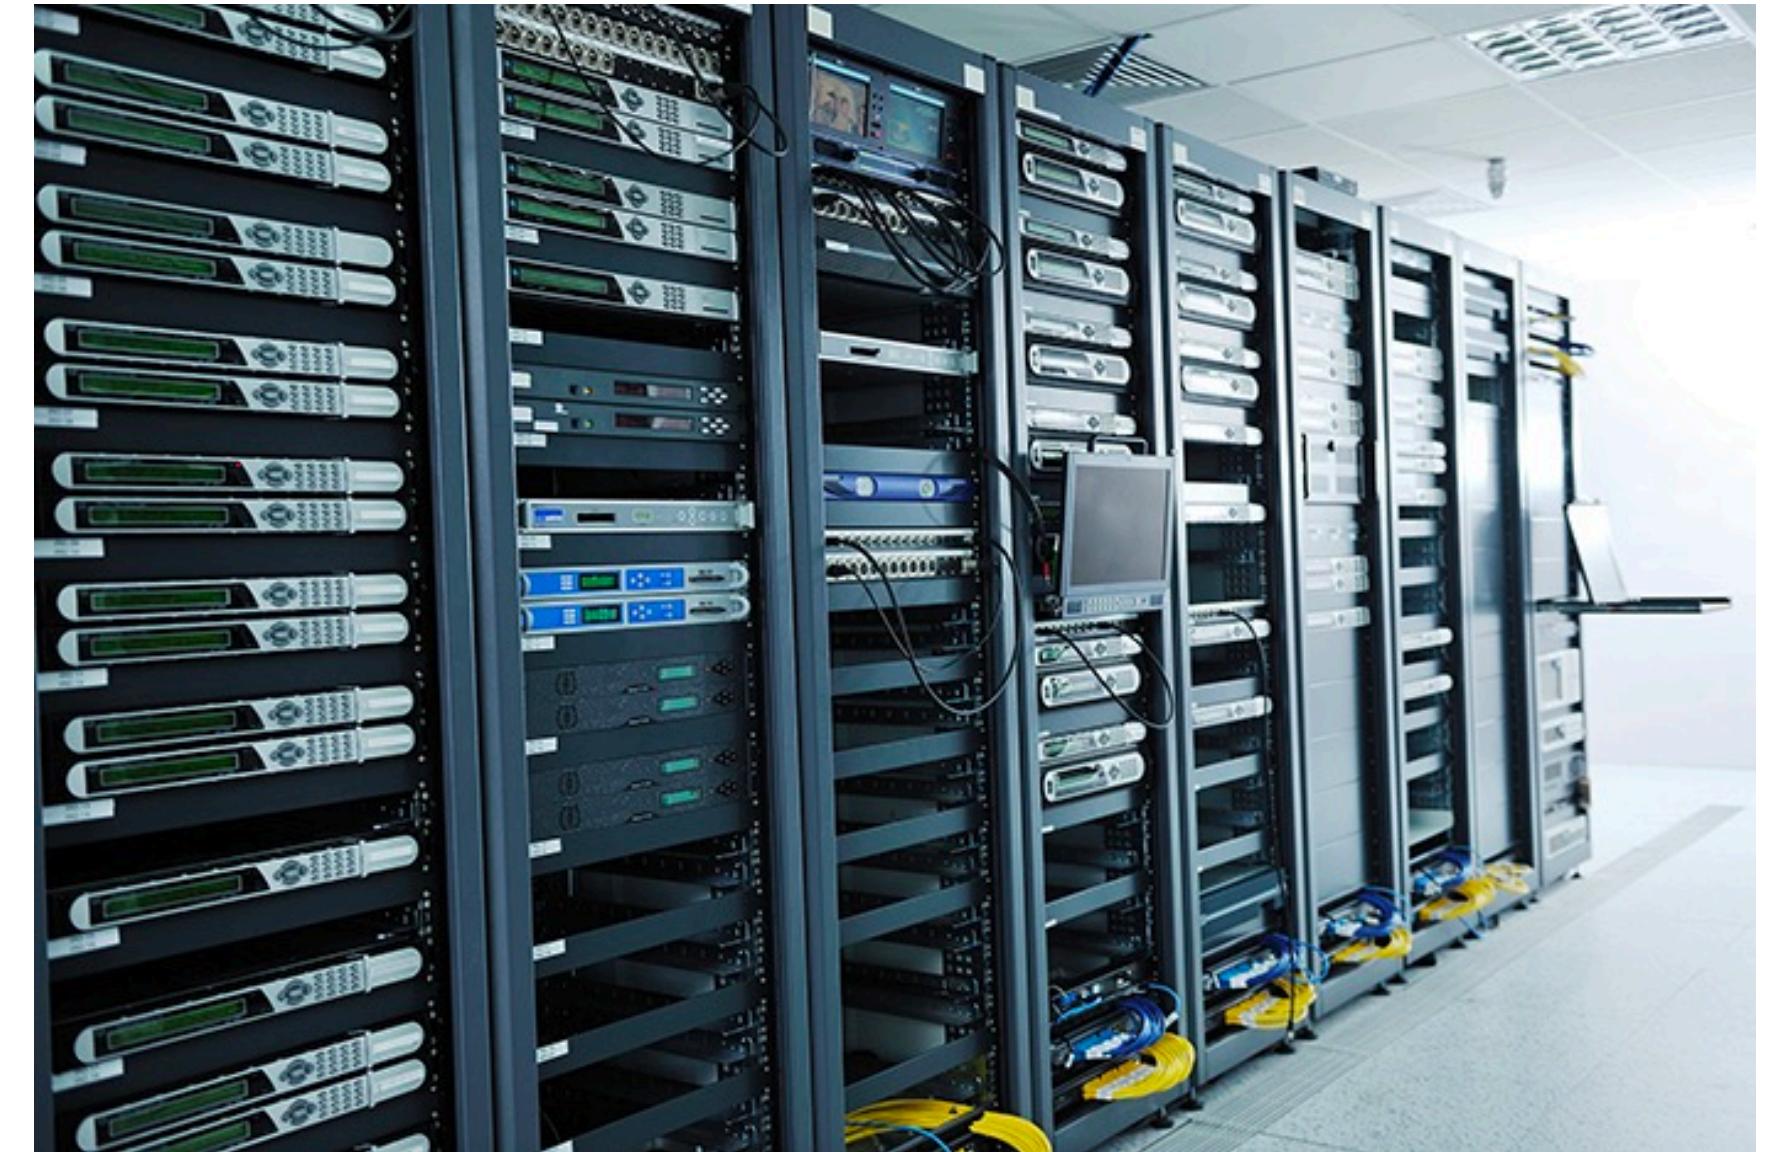
1. Eliminando sensores
2. Realizando menos mediciones por sensor

MARCO TEÓRICO

CENTROS DE PROCESADO DE DATOS

- › Colocación de servidores en racks
- › Los racks se agrupan en filas
- › Para medir su eficiencia energética se usa el Power Unit Efficiency (PUE):

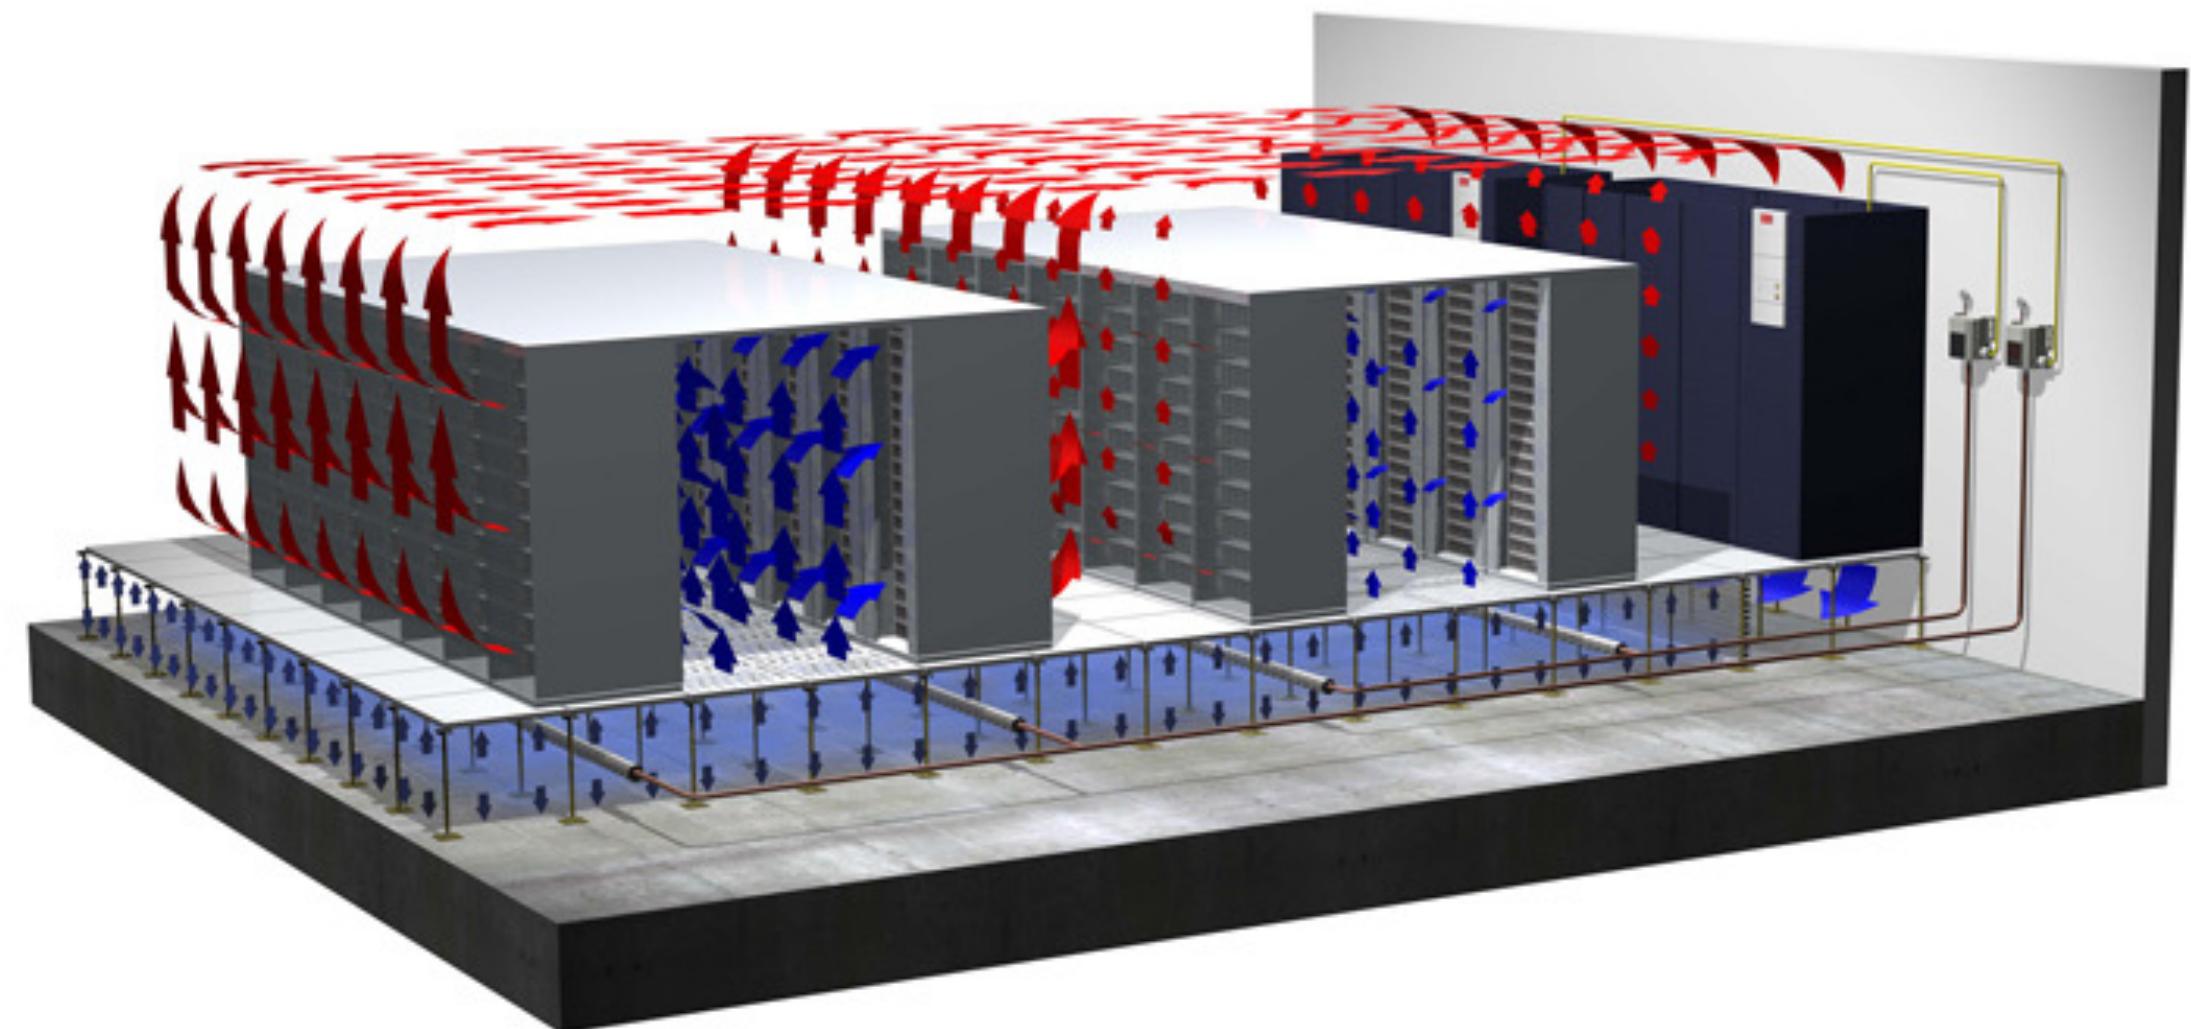
$$PUE = \frac{EnergiaTotalCPD}{EnergiaSistemasIT}$$



SISTEMA DE REFRIGERACIÓN

- › Diferenciación entre:
 - › Pasillo caliente 
 - › Pasillo frío 
- › Uso de CRAC para refrigerar
- › Temperaturas relevantes:
 - › Inlet
 - › Outlet
 - › Return
 - › Supply

CRAC: Aire Acondicionado Para
Sala De Computadoras



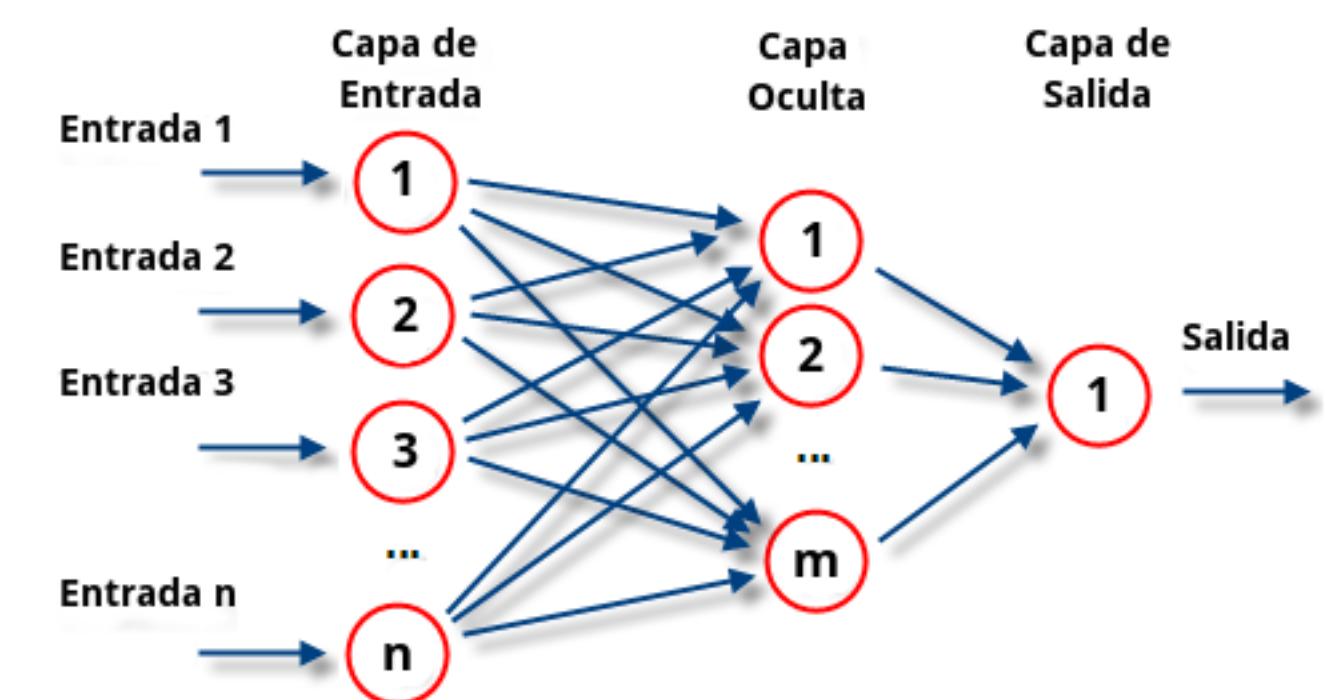
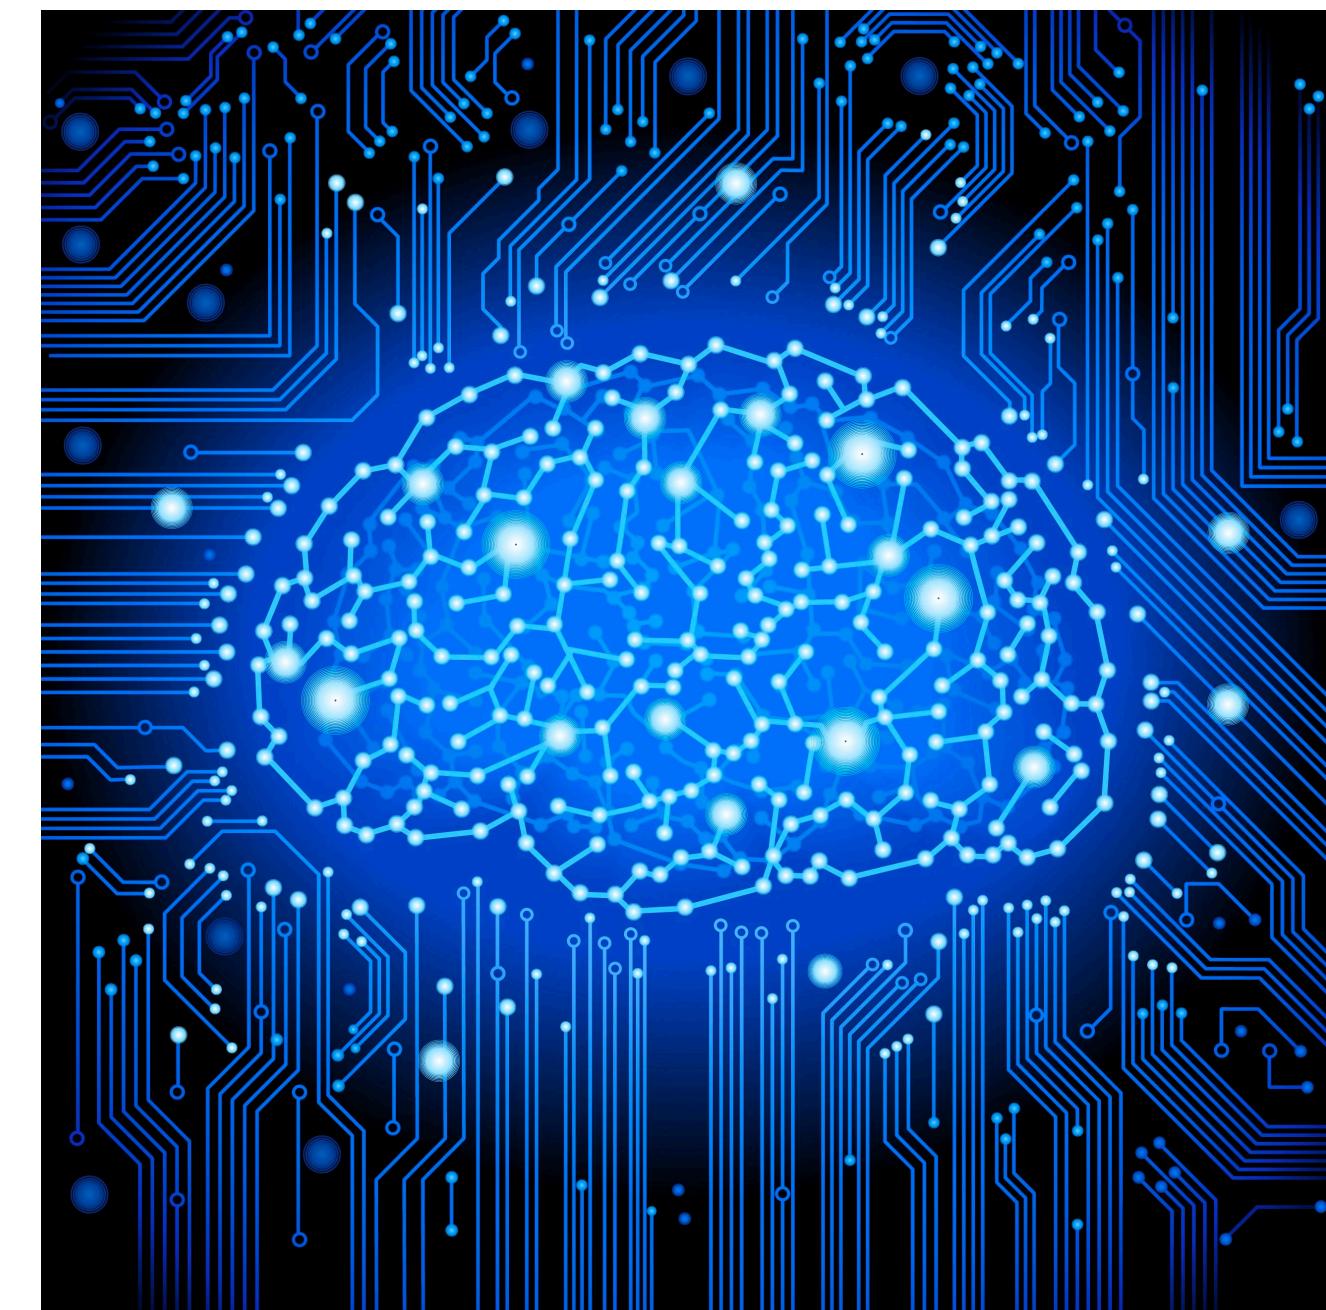
Interesa predecir la temperatura con cierta anticipación para adaptar el nivel de refrigeración del CRAC

→ ¿ALTERNATIVAS?

REDES NEURONALES ARTIFICIALES

- › Simulación de las neuronas humanas
- › Refuerzan las conexiones en cada iteración para predecir con mayor acierto
- › Redes Neuronales Recurrentes
 - › Buena predicción de valores futuros
- › Redes Neuronales Convolucionales
 - › Mejor reconocimiento de parámetros

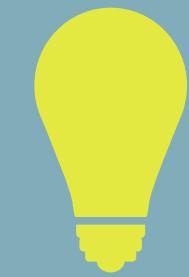
Células GRU



ESTADO DEL ARTE

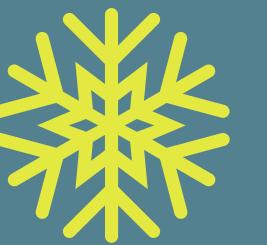
ESTADO DEL ARTE

GREEN COMPUTING



FREE COOLING TECHNIQUES

- APROVECHAN TEMPERATURA EXTERIOR



MACHINE LEARNING

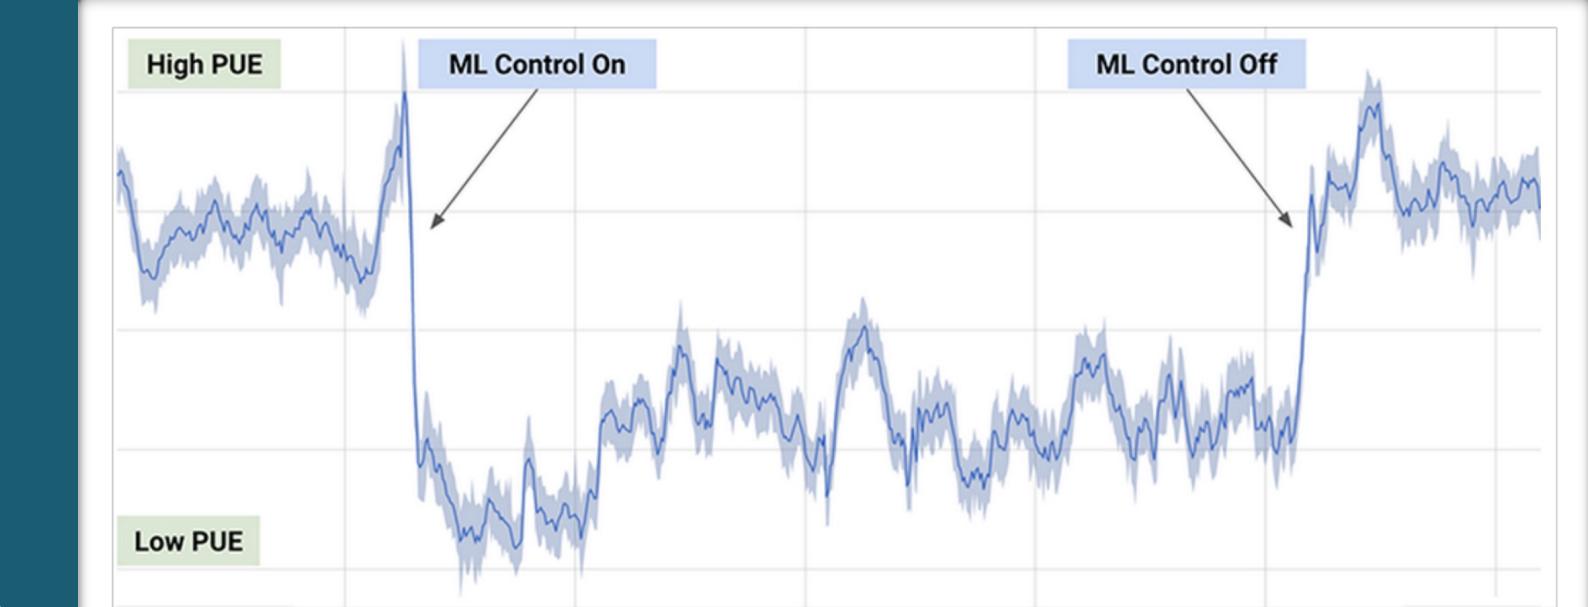
- USO DE APRENDIZAJE AUTOMÁTICO PARA PREDECIR TEMPERATURA O PUE



CONTROL DE SISTEMA DE REFRIGERACIÓN

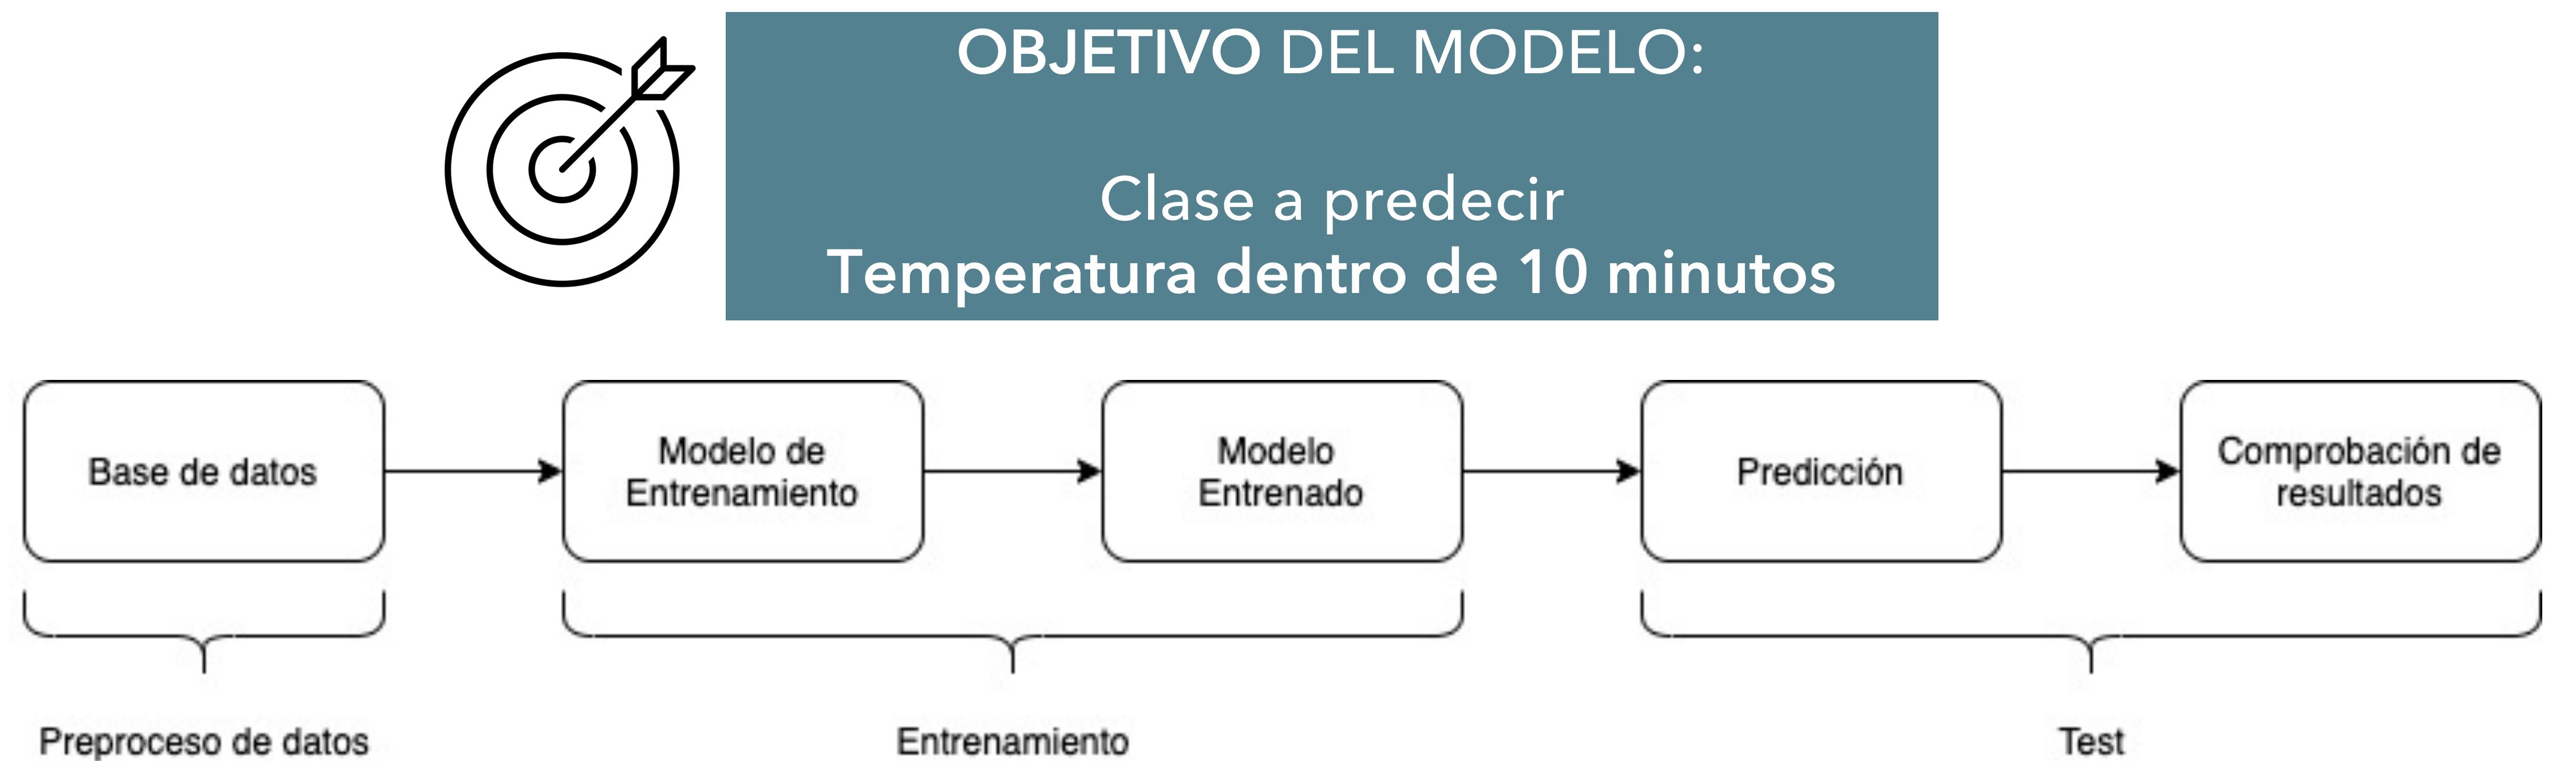
- REDES NEURONALES OFRECEN GRAN RENDIMIENTO

- REDUCCIÓN DE HASTA UN 40%

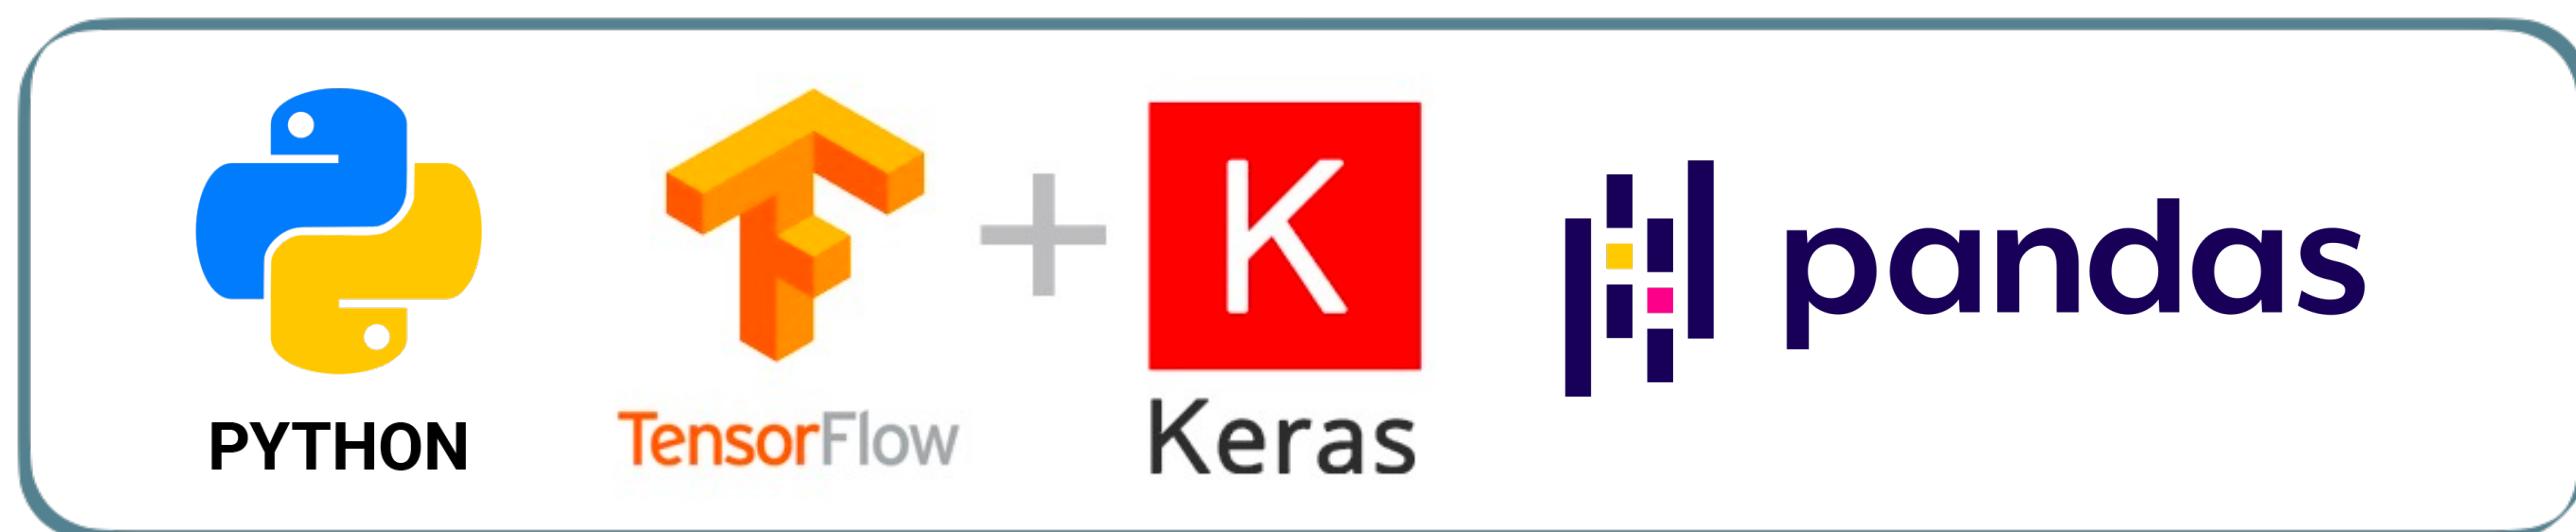


DESARROLLO

PROCESO DE DESARROLLO DEL MODELO

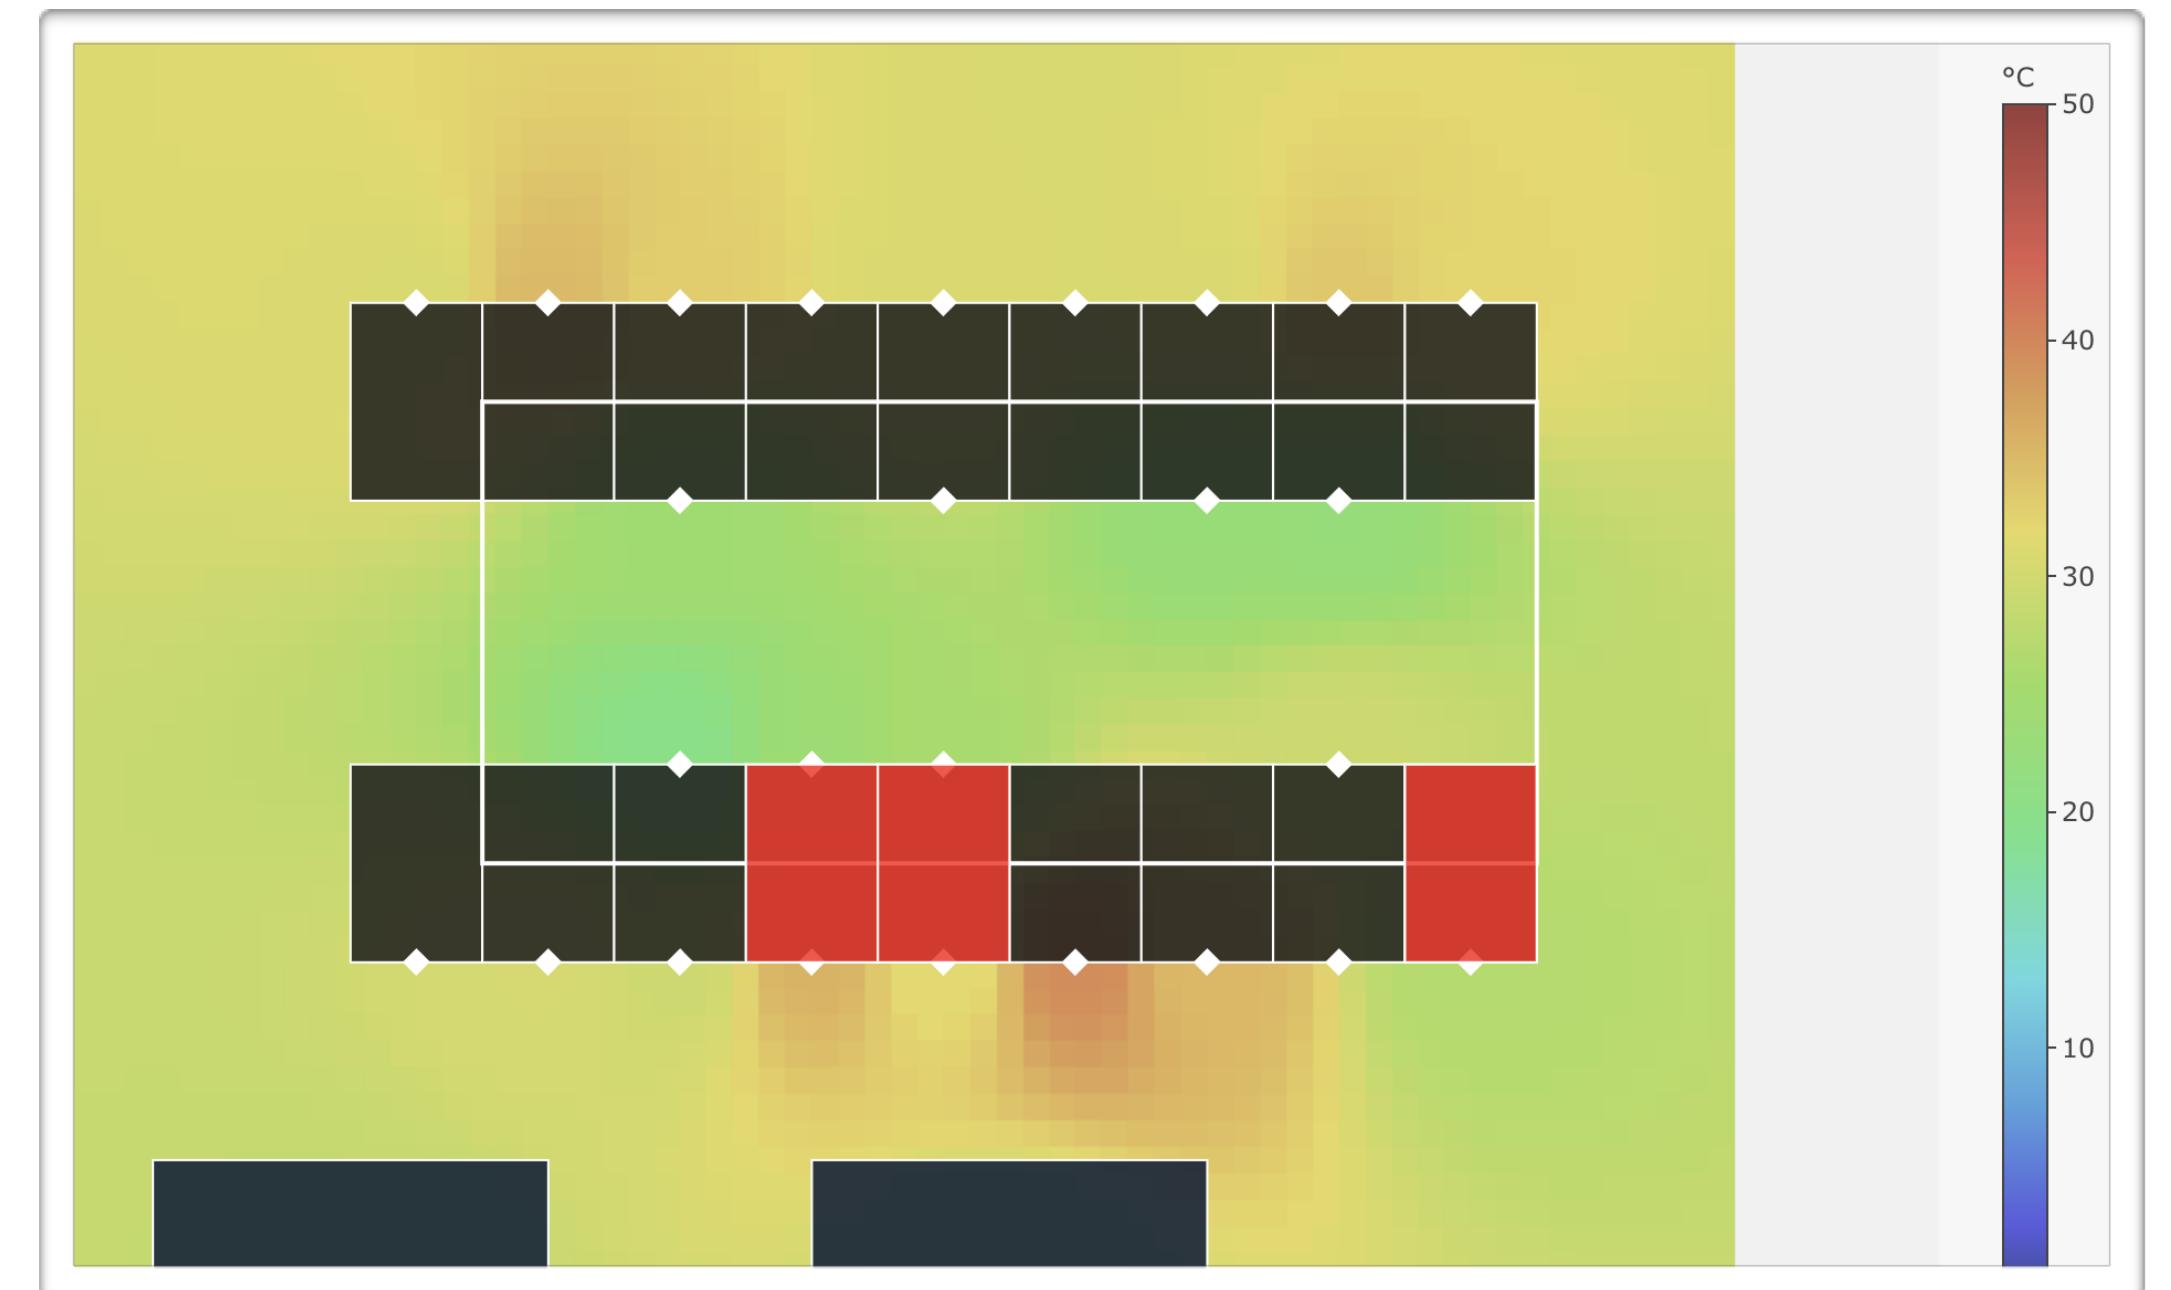


HERRAMIENTAS



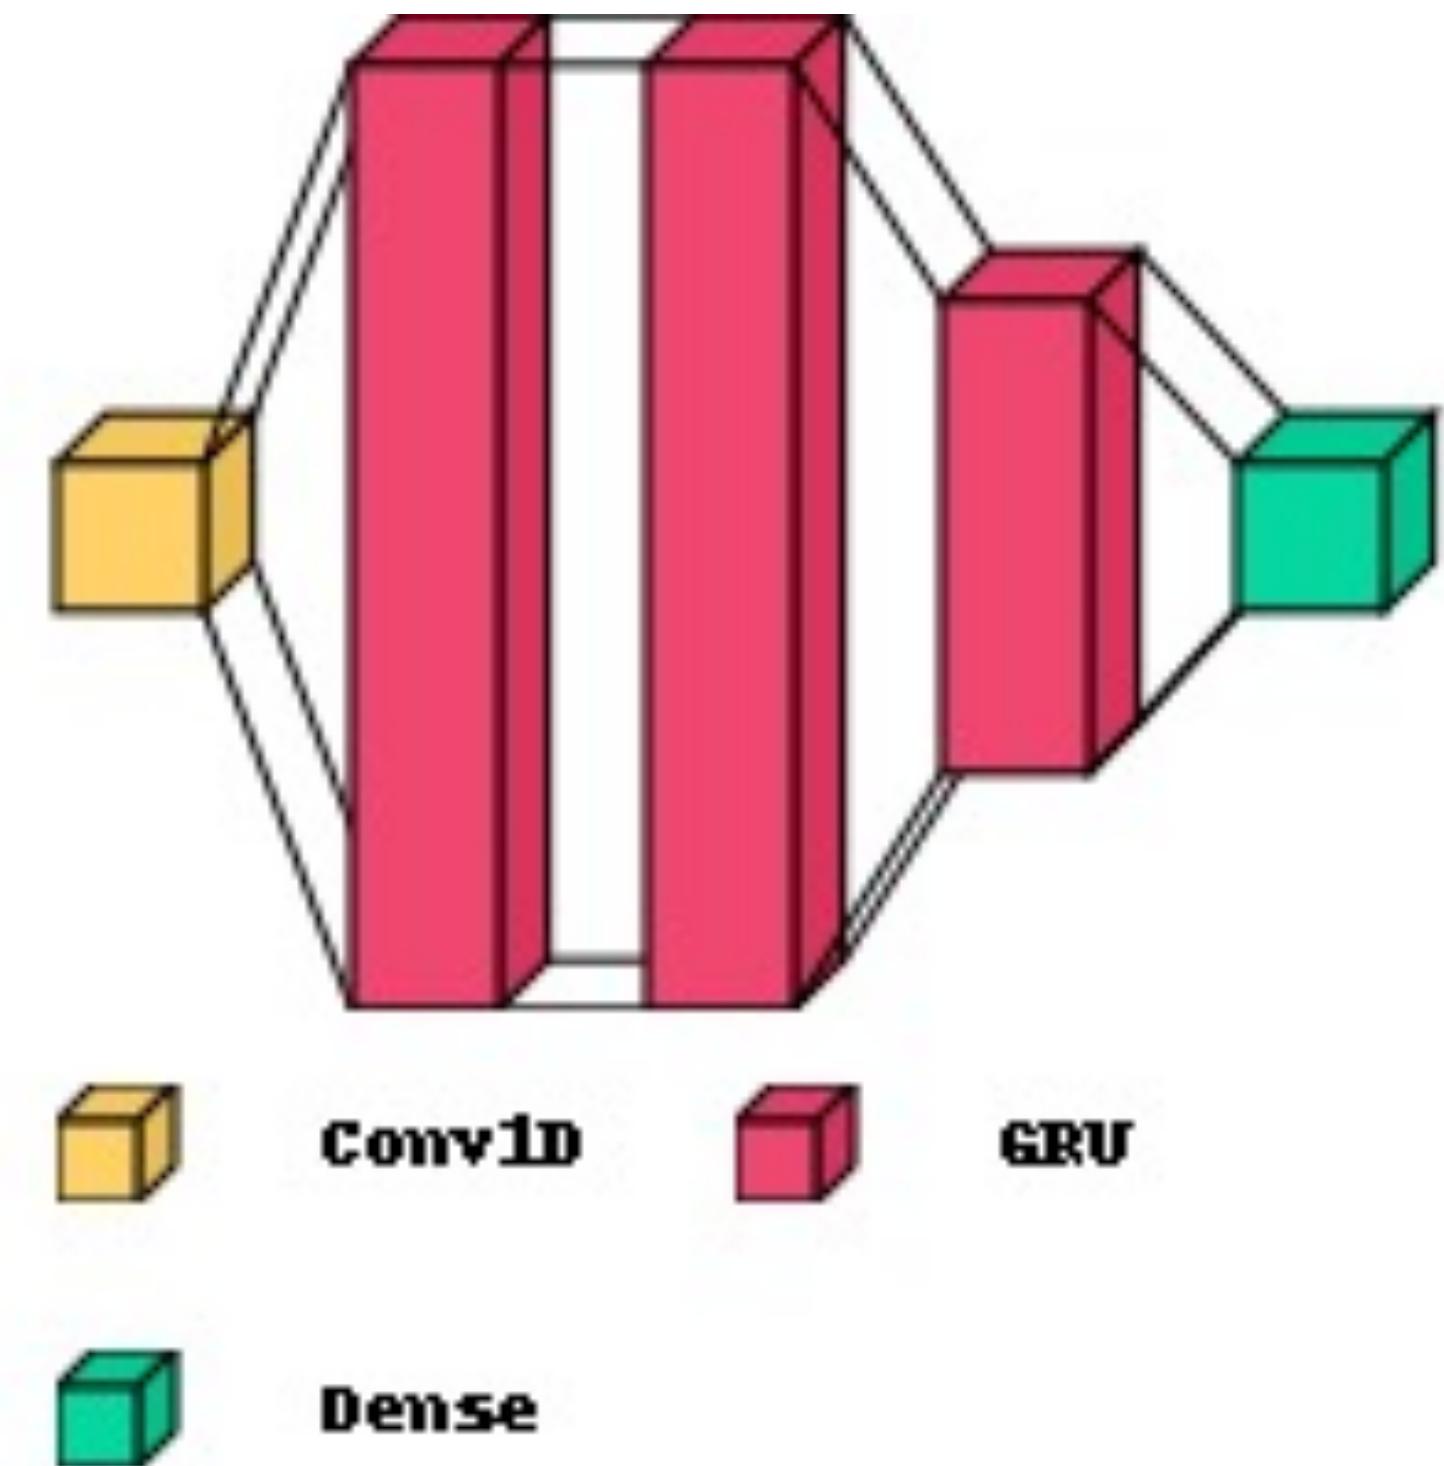
DATOS DE ENTRADA

- › Dataset obtenido con mediciones reales de 70 sensores de una sala de servidores real
- › Atributos
 - › temperatura, humedad, x, y, z
- › Normalización de valores entre 0 y 1
- › Separación entre distintos tipos de temperatura



DISEÑO DE LA RED NEURONAL

- **Convolutional-1D**
 - Prepara la entrada a GRU
 - Reconocimiento de patrones
- **GRU Layer**
 - Poseen memoria
 - Predicción de valores futuros
- **Dense Layer (salida)**



ENTRENAMIENTO

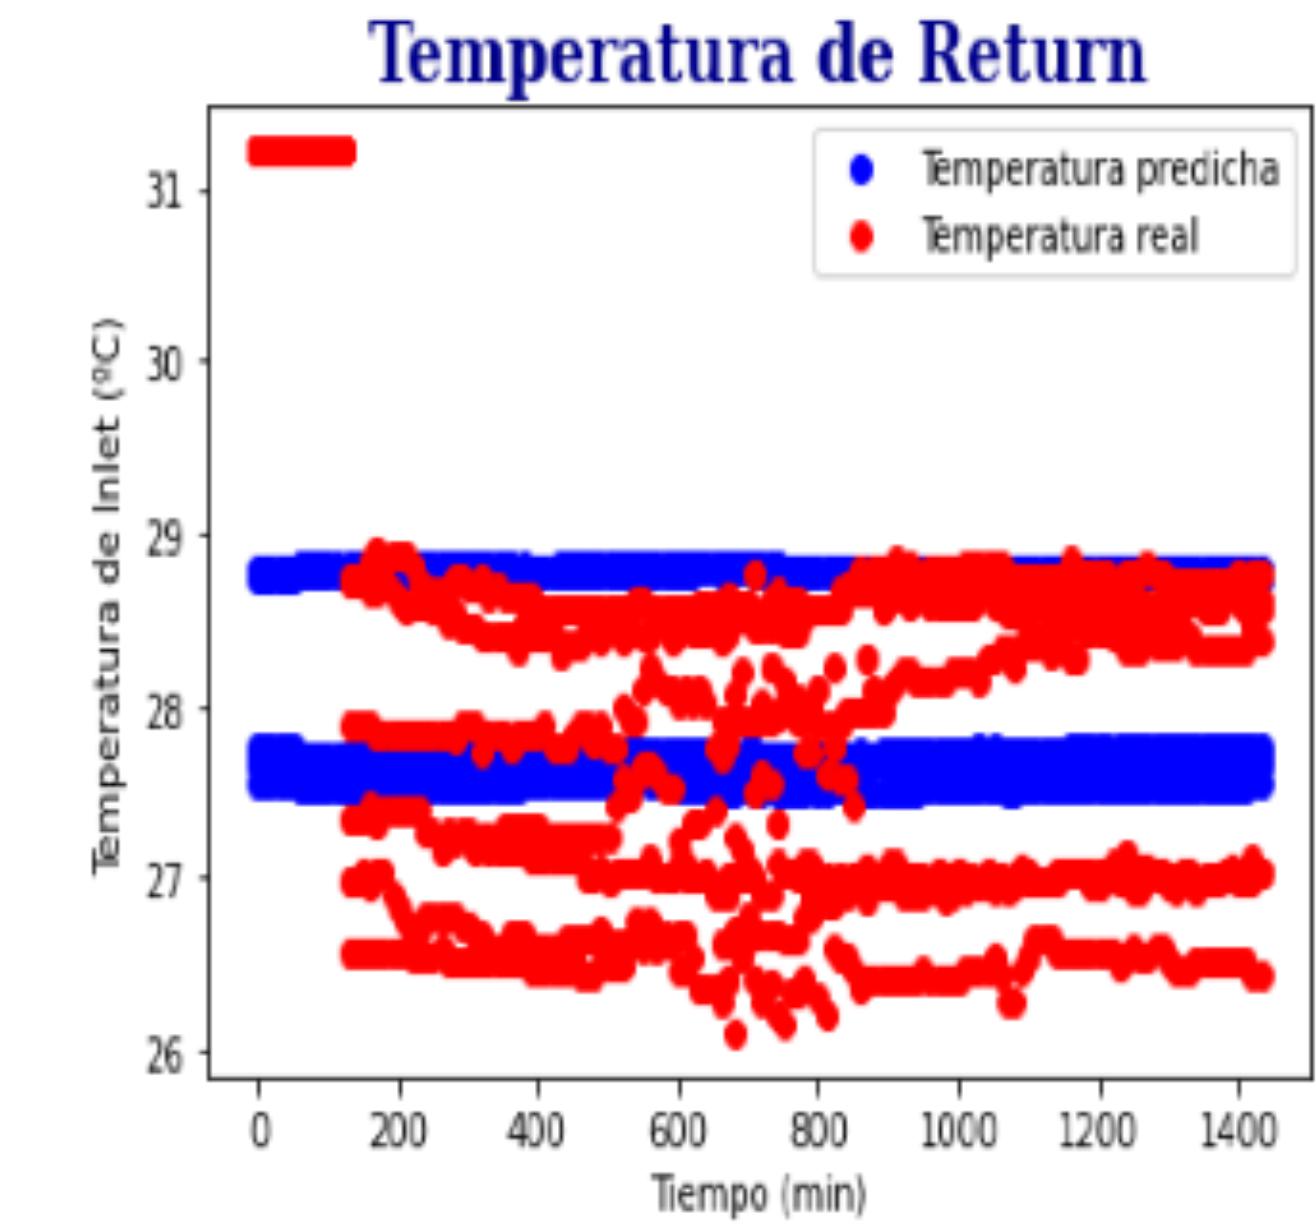
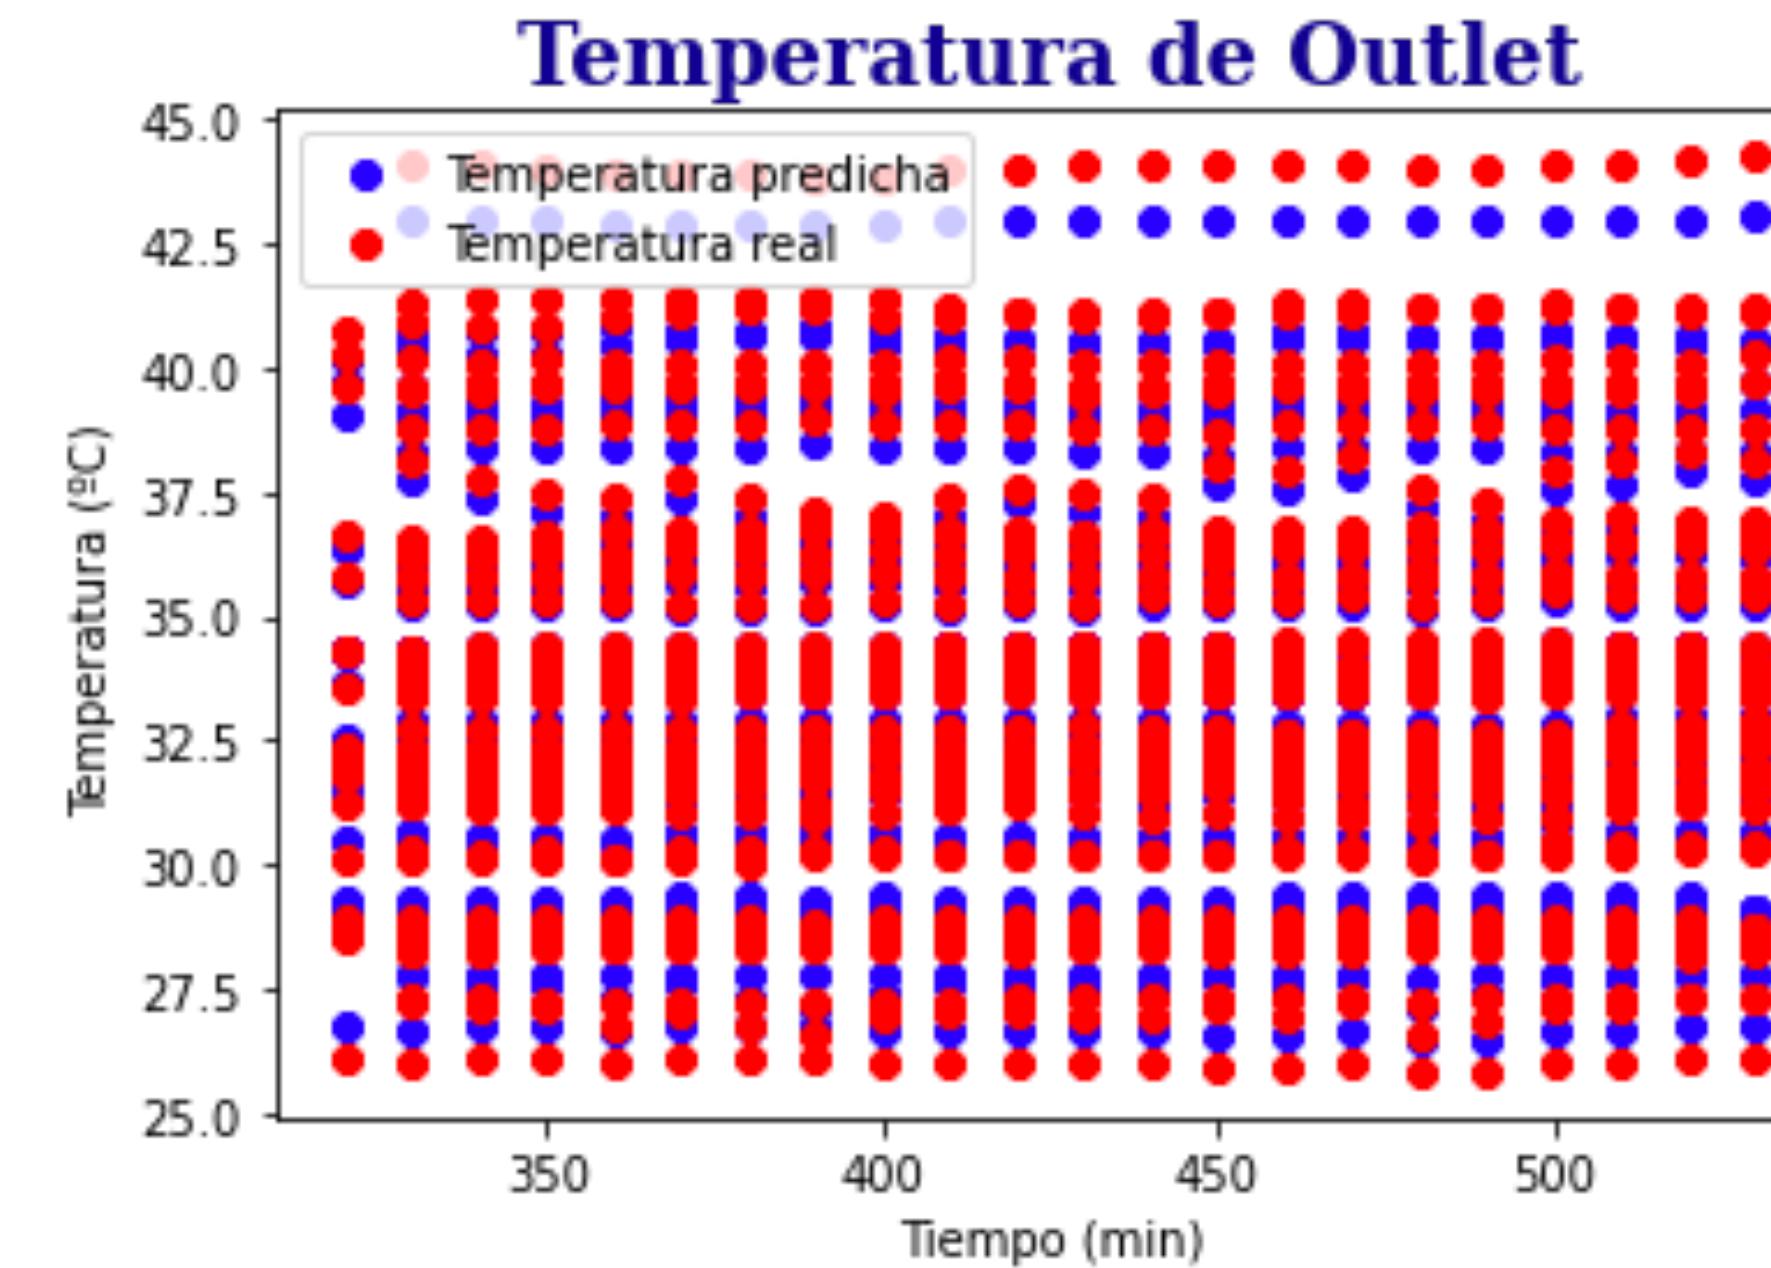
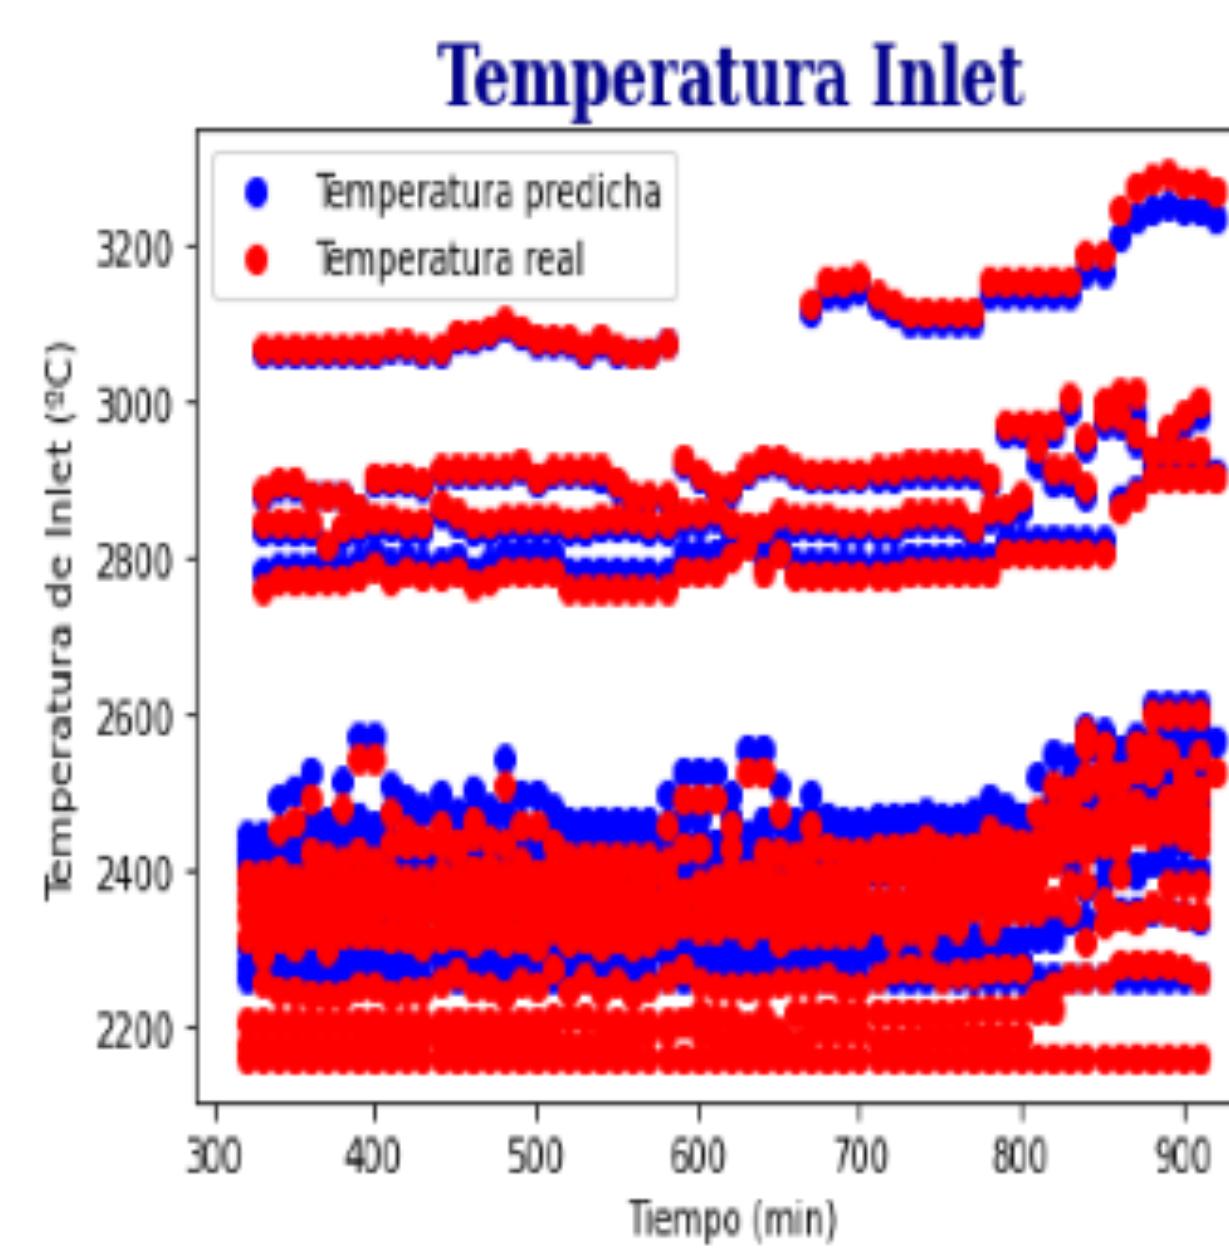
- › Uso del 66% de los datos para entrenamiento y 33% para test
- › Uso del error cuadrático medio para medir acierto (MSE)
- › Modelo
 - › Optimización a través de descenso de gradiente (Adam)
 - › Batch size: 32

Capa	Tipo	Tamaño Kernel	Stride	Función Activación	Size/ N° Neuronas
Conv1D	CNN	4	1	relu	(None,1)
GRU	RNN	N/A	N/A	tanh	32
GRU	RNN	N/A	N/A	tanh	32
GRU	RNN	N/A	N/A	tanh	16
Dense	Salida	N/A	N/A	Sigmoid	1

RESULTADOS

EXPERIMENTO GLOBAL

Temperatura	Tiempo de ejecución	RMSE
Inlet	44 min 47 seg	1,91183812
Outlet	1 h 3 min 0 seg	1,43718475
Return	1 min 45 seg	1,19143821



EXPERIMENTO REDUCIENDO MEDICIONES (I)

- › Realizar una medición consume batería del sensor → disminuye su vida útil
- › ↓ Mediciones por sensor → ↑ duración del sensor → ↓ desgaste económico

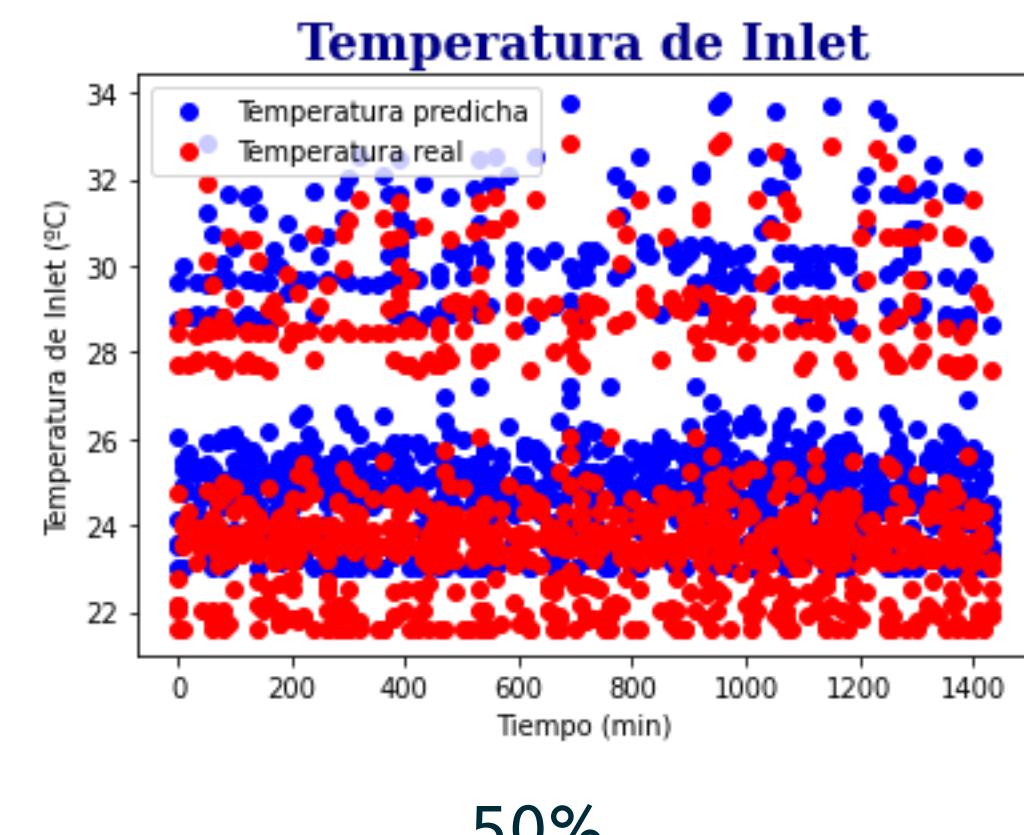
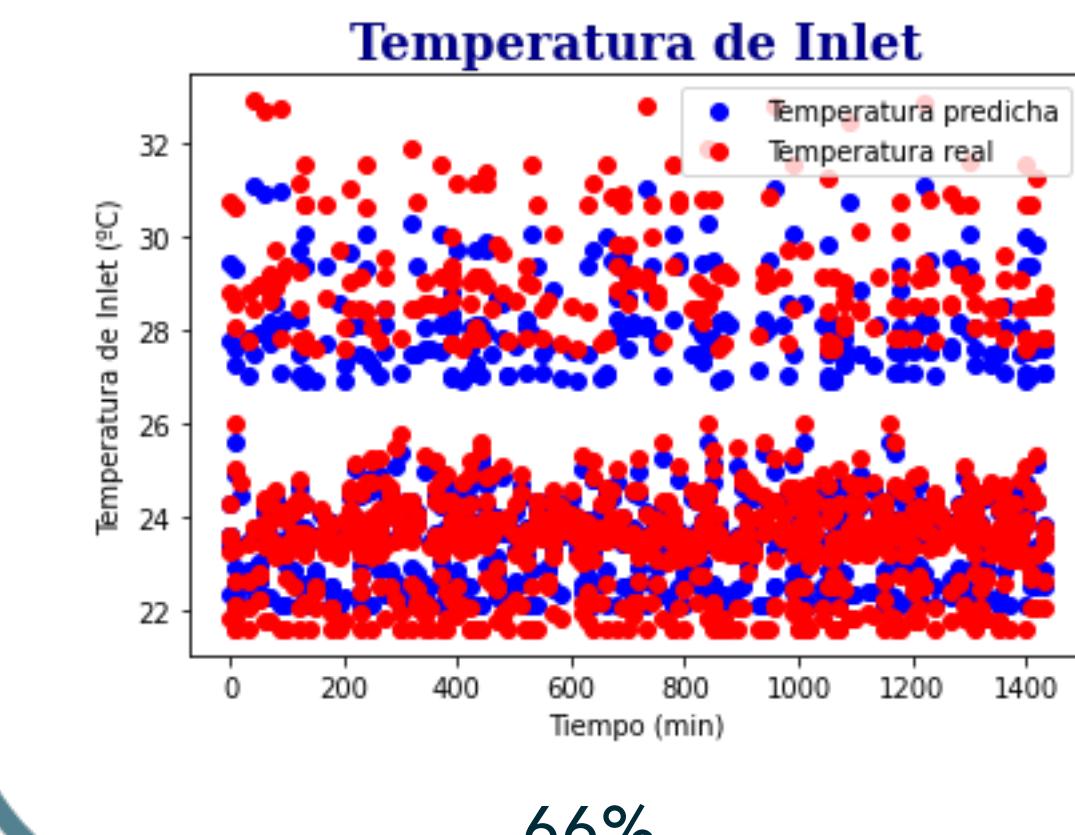
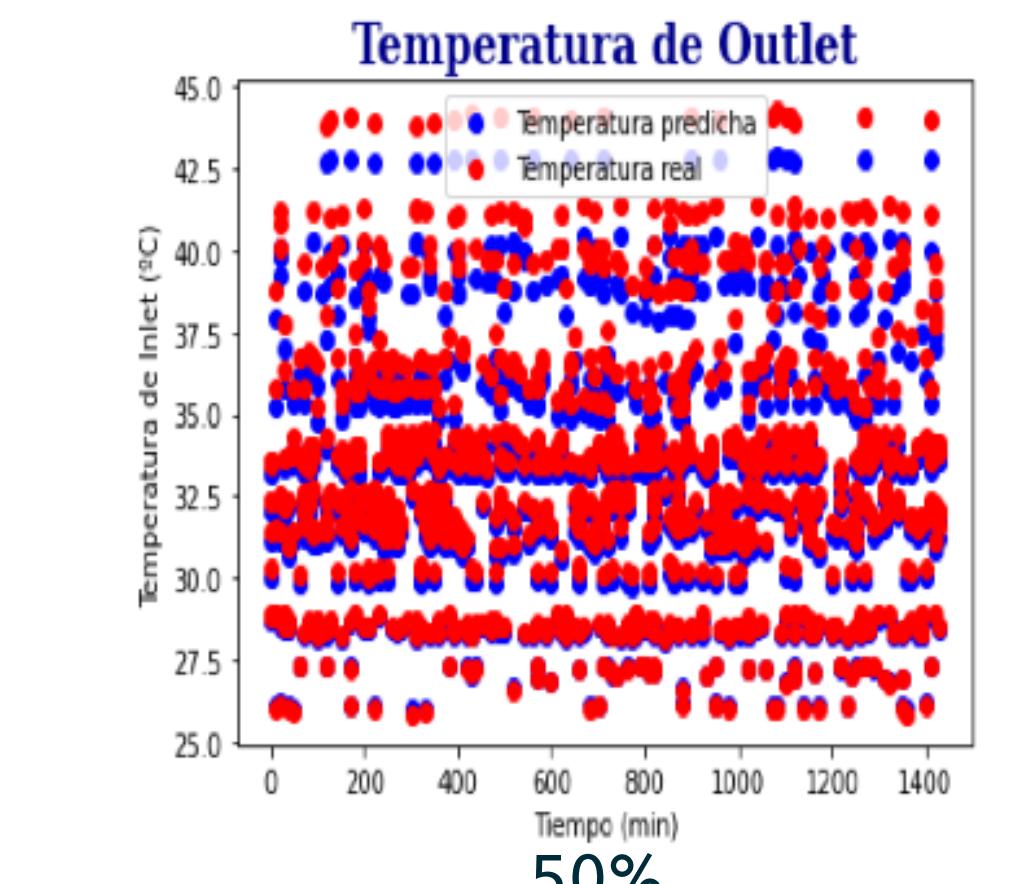
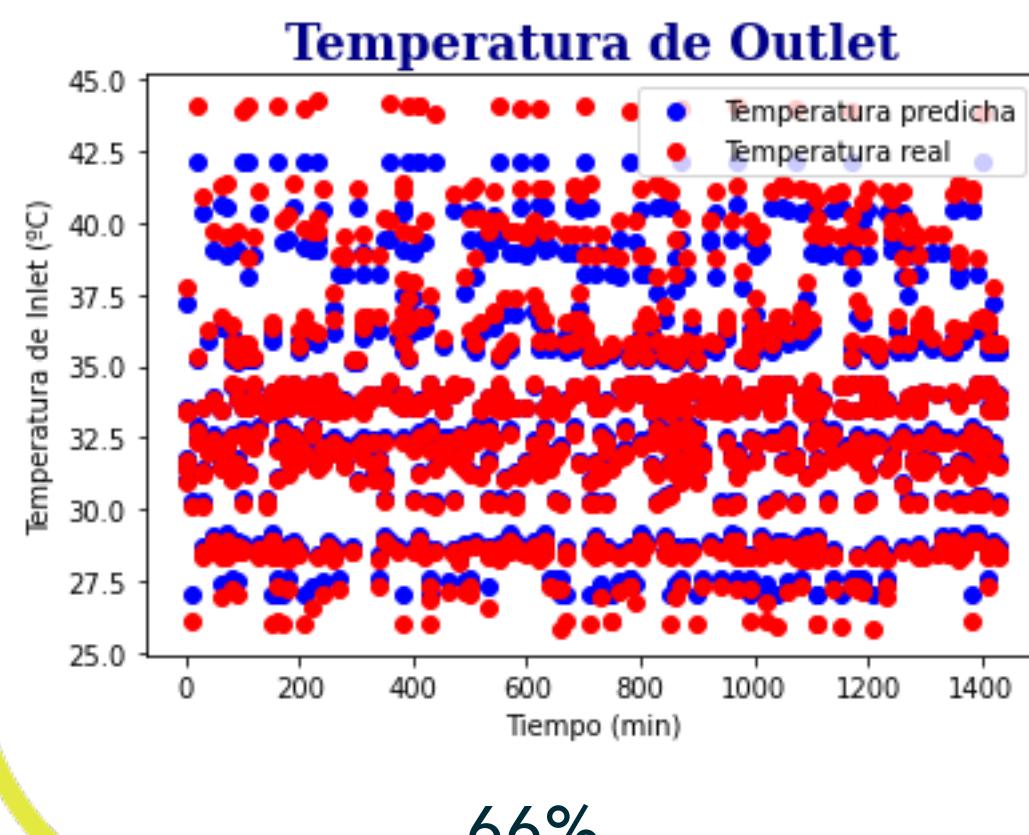
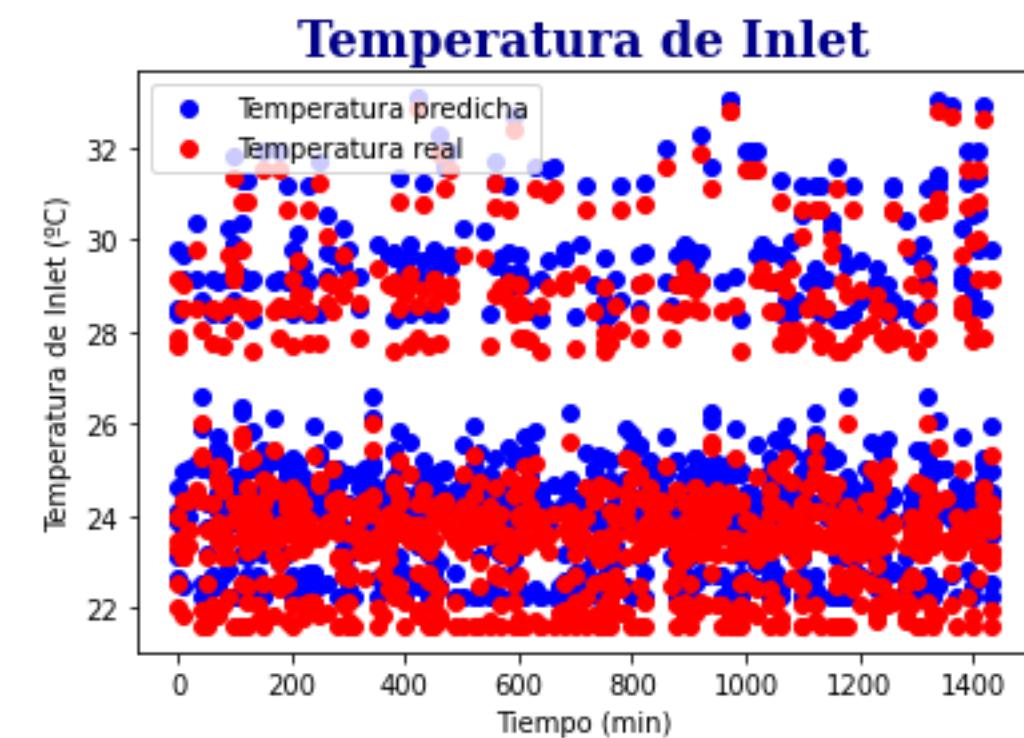
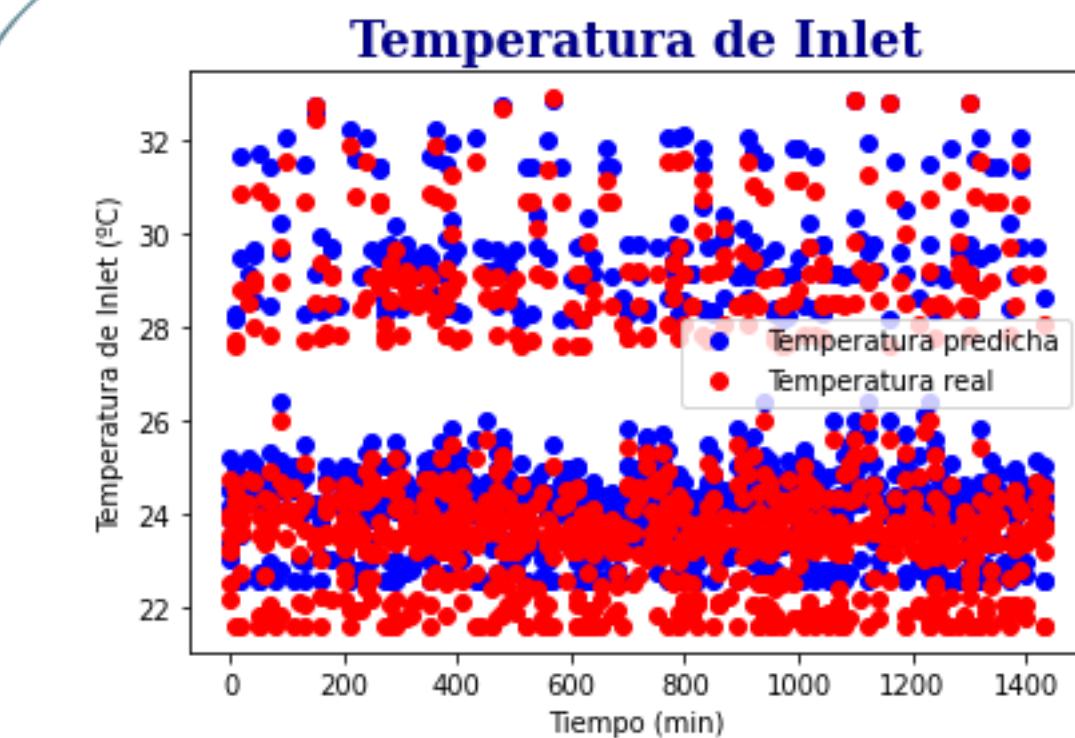
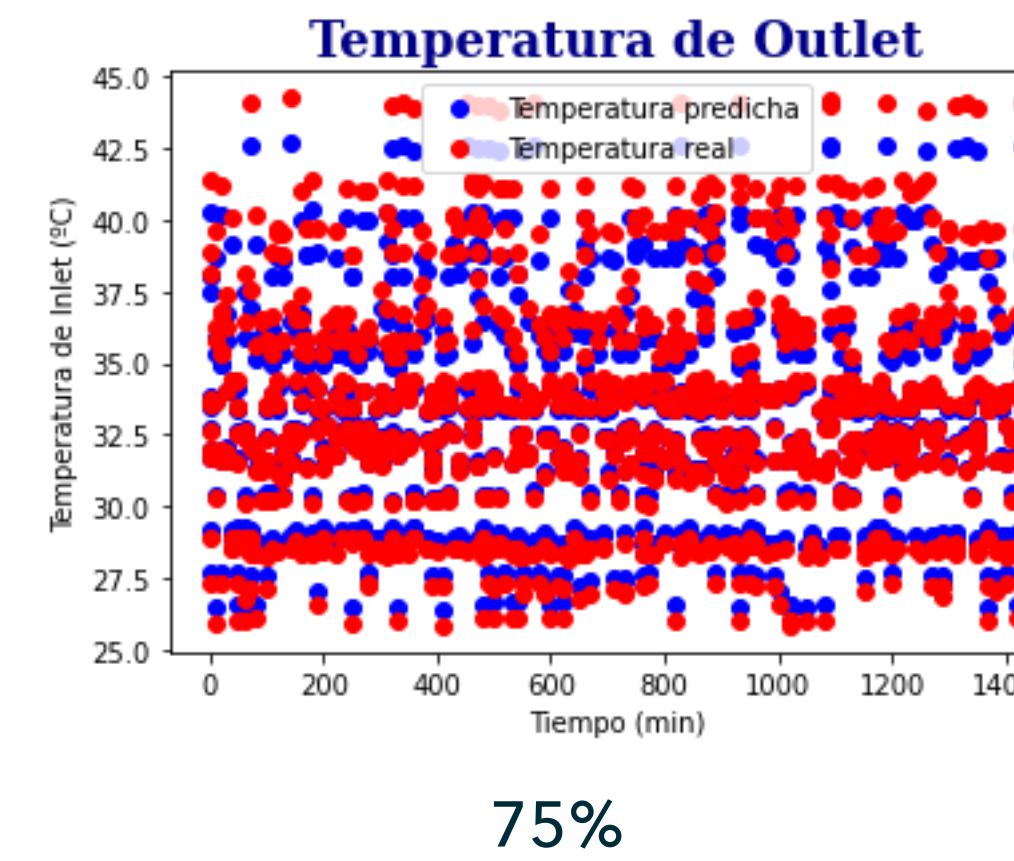
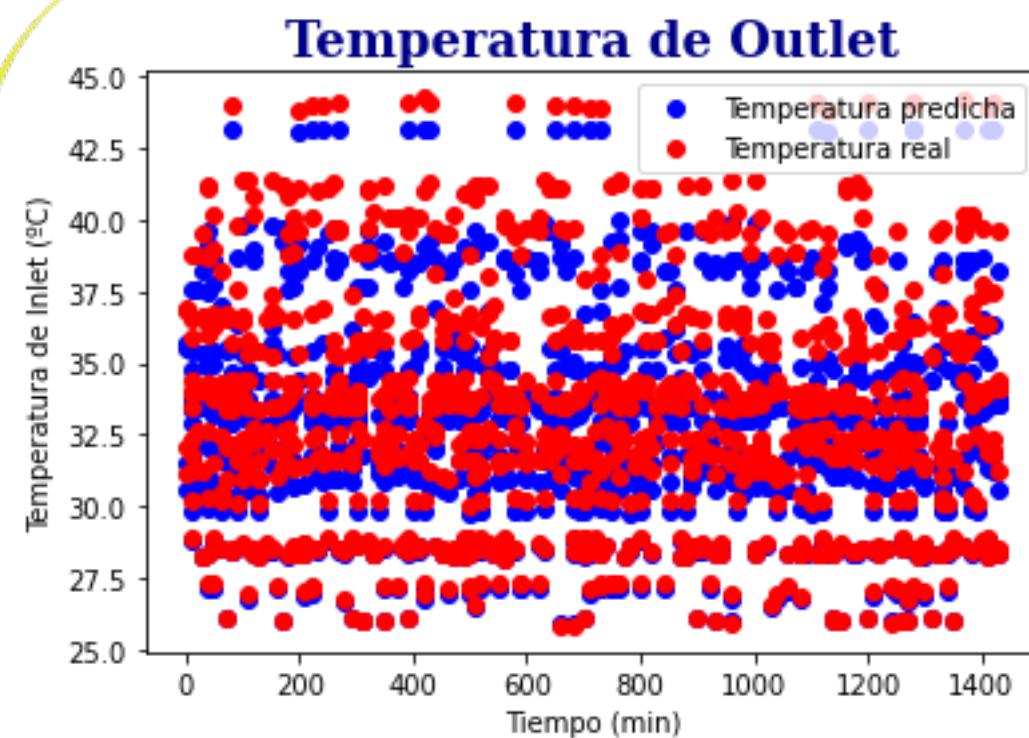


- › El experimento consiste en:
 - › Eliminar muestras aleatorias y comprobar si se mantiene la precisión del modelo

Temperatura	% datos	Tiempo de ejecución	RMSE
Inlet	90	10 min 16 seg	2,03447782
	75	9 min 8 seg	2,06853209
	66	7 min 6 seg	1,89534957
	50	4 min 16 seg	1,90600367
Outlet	90	51 min 46 seg	1,50262271
	75	42 min 15 seg	1,40223928
	66	35 min 26 seg	1,43153763
	50	33 min 54 seg	1,44210783



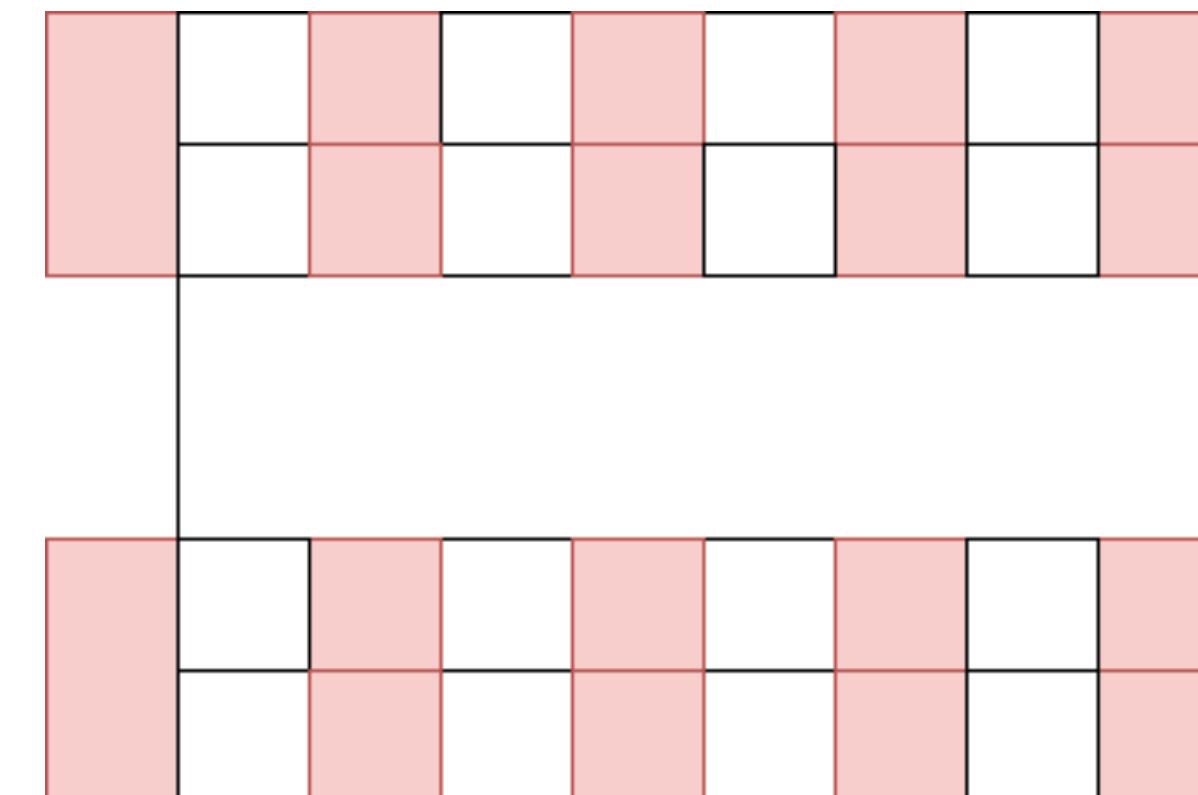
EXPERIMENTO REDUCIENDO MEDICIONES (II)



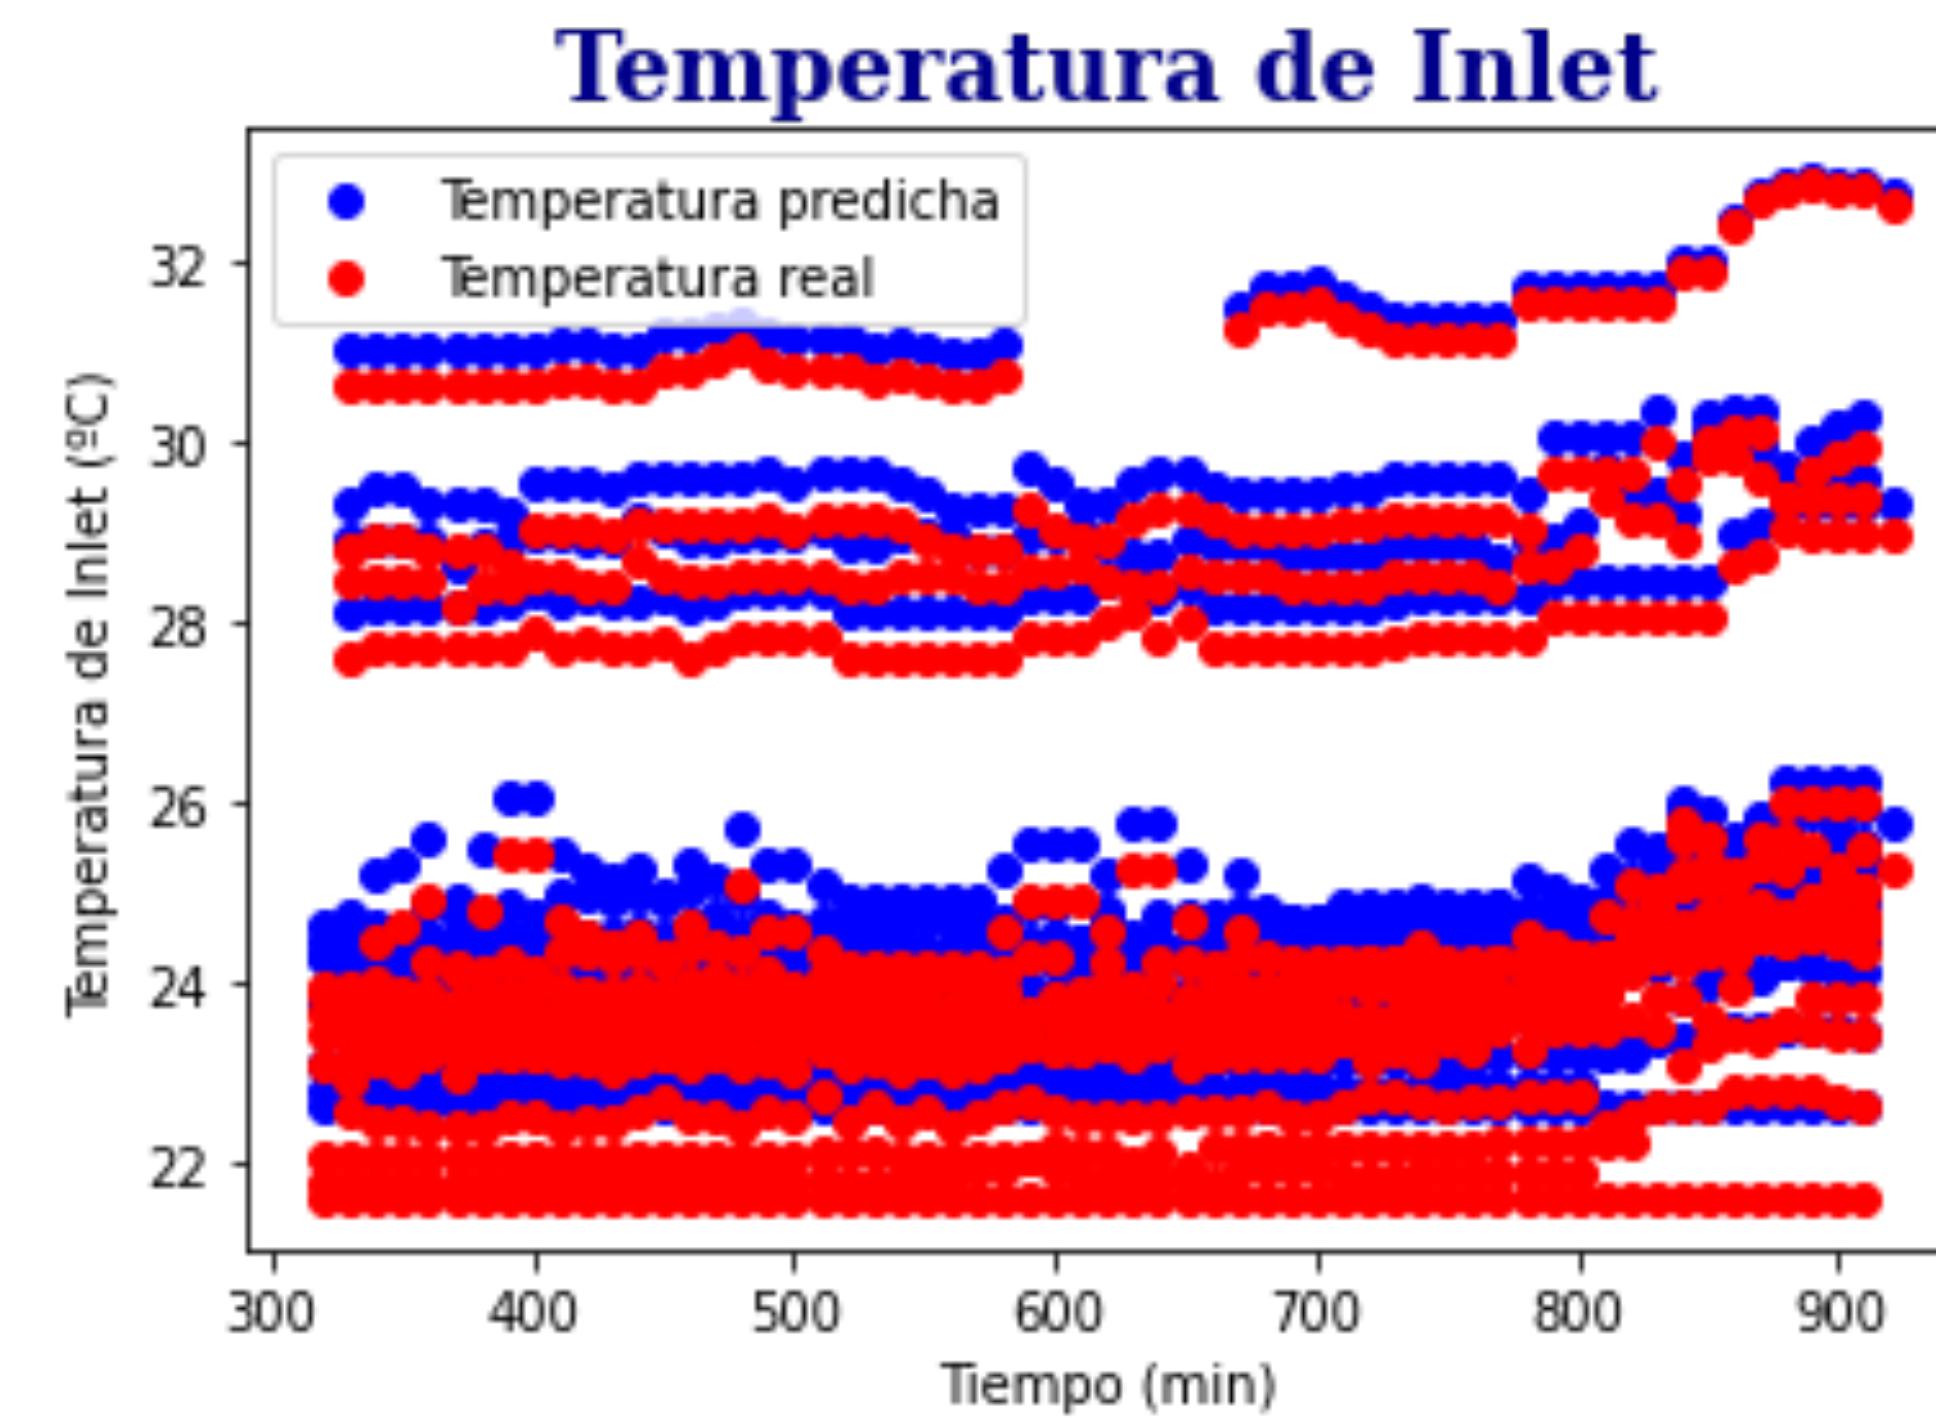
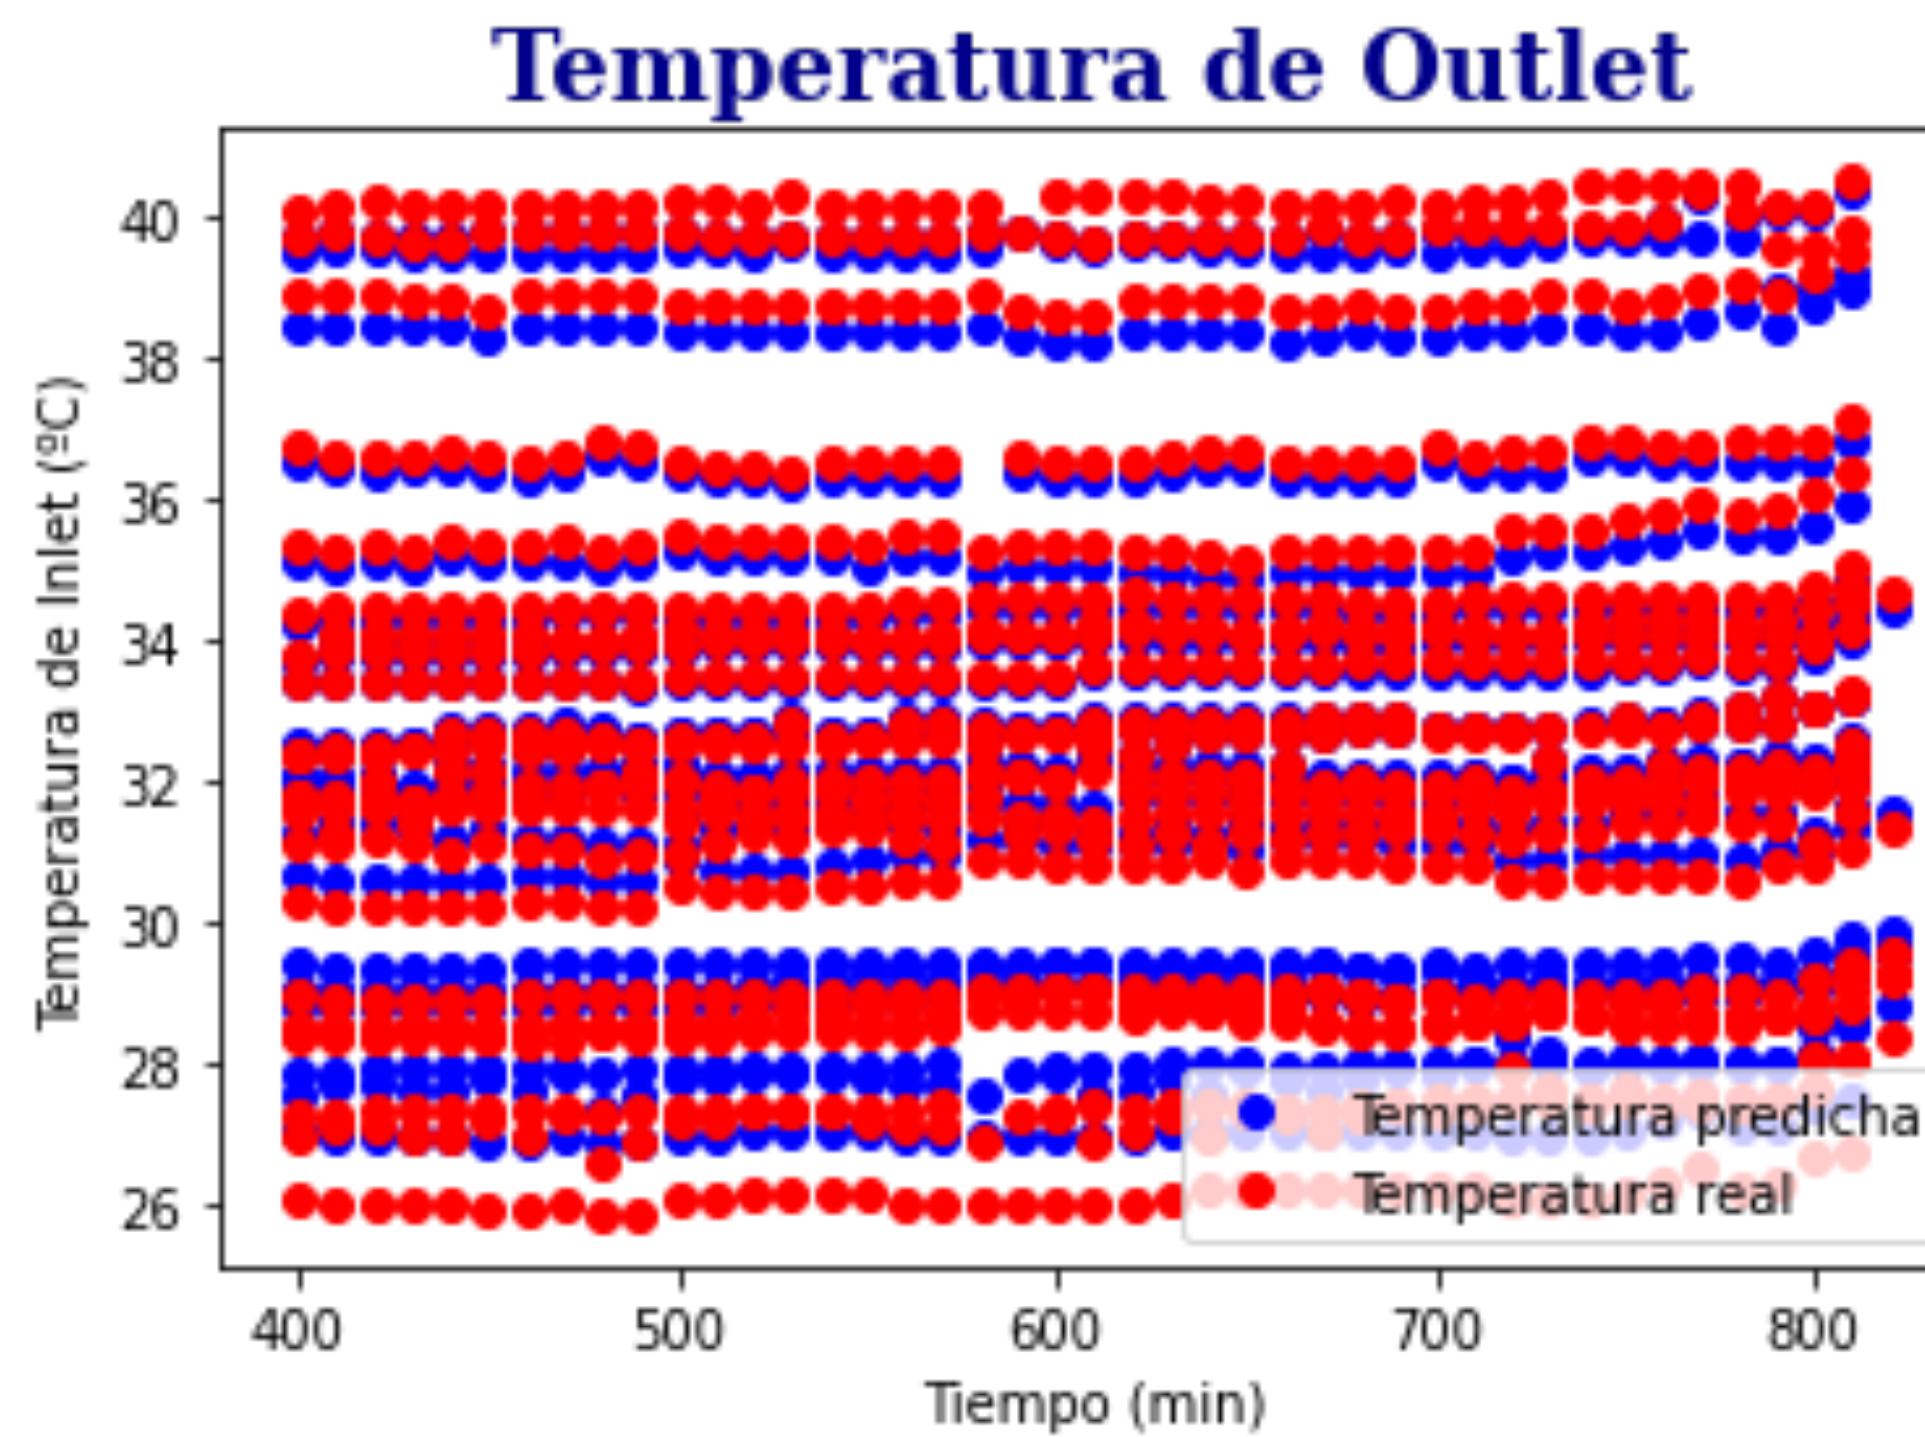
EXPERIMENTO REDUCIENDO SENsoRES (I)

- › Se estudiará una posible reducción de sensores, manteniendo la precisión del modelo
- › Se hace una distribución uniforme por racks → ↓ número de sensores a 35
- › Reducción del coste económico ↓ 

Temperatura	Tiempo de ejecución	RMSE
Inlet	3 min 1 seg	1,90228152
Outlet	38 min 30 seg	1,44491349



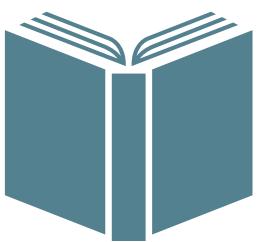
EXPERIMENTO REDUCIENDO SENsoRES (II)



CONCLUSIONES

CONCLUSIONES (I)

1. **Se adquieren conocimientos en:**



1. Centros de datos y sistema de refrigeración
2. Aprendizaje automático y redes neuronales
3. Python, TensorFlow y Keras

2. **Se alcanza un modelo que predice la temperatura con gran precisión:**



1. Temperatura Inlet: RMSE = 1,911
2. Temperatura Outlet: RMSE = 1,437
3. Se podría controlar un sistema de refrigeración generando ahorro energético



CONCLUSIONES (II)

3. Reducción del número de mediciones sin perder precisión de predicción:

1. Se usan 35 sensores menos, mediante una distribución uniforme:
 1. Temperatura Inlet: RMSE = 1,902
 2. Temperatura Outlet: RMSE = 1,444
2. Con el 50% de las mediciones disponibles en Outlet y con el 66% en Inlet
 1. Temperatura Inlet: RMSE = 1,906
 2. Temperatura Outlet: RMSE = 1,431
3. Se comprueba que se podría realizar un importante ahorro económico 

PREGUNTAS